# Conceitos de Engenharia de Dados

Asimov Academy

ASIMOV

# Conteúdo

**A Era dos Dados** **3**
A Revolução dos Dados: Transformando Indústrias e Profissões . . . 3
A Indústria dos Dados . . . 4
Dados Estruturados e Não Estruturados: O Alicerce da Era da Informação . . . 6
Exemplos de Dados Estruturados . . . 6
Exemplos de Dados Não Estruturados . . . 7
A Importância do Engenheiro de Dados na Era da Informação . . . 7
O que você aprendeu . . . 8
Novas Palavras-Chave . . . 8

**O Papel do Engenheiro de Dados** **10**
Qual o papel do Engenheiro de Dados? . . . 10
Engenheiro de Dados . . . 10
Principais Atribuições do Engenheiro de Dados . . . 11
Descrição de Competências do Engenheiro de Dados . . . 12
Cientista de Dados . . . 12
Principais Atribuições do Cientista de Dados . . . 13
Descrição de Competências do Cientista de Dados . . . 13
Engenheiro de Dados vs Cientista de Dados . . . 13
Impacto do Engenheiro de Dados nas Organizações . . . 14
Decisões Baseadas em Dados . . . 14
Exemplos de Projetos de Engenharia de Dados . . . 16
Exemplo 1: *Pipeline* para Atualização de Dados de Vendas . . . 16
Exemplo 2: *Pipeline* de Monitoramento de Tráfego de Site . . . 16
Exemplo 3: *Pipeline* para Dados de Sensores de uma Fábrica . . . 17
O que você aprendeu . . . 17

**Conceitos Essenciais** **18**
O que é Data Pipeline? . . . 18
Data Pipeline e a Engenharia de Dados . . . 21
*Data Lake* vs *Data Warehouse*: Uma Visão de *Big Data* . . . 25
O que é ***Big Data***? . . . 25
O que é um ***Data Lake***? . . . 26
O que é um ***Data Warehouse***? . . . 27
Comparação: ***Data Lake*** vs ***Data Warehouse*** . . . 28

Ferramentas e Tecnologias Utilizadas . . . . . 28
**Ferramentas Offline (Locais)** . . . . . 28
**Ferramentas de Nuvem** . . . . . 30
Comparação das Ferramentas Offline e Nuvem . . . . . 31
O que você aprendeu . . . . . 32

# A Era dos Dados

## A Revolução dos Dados: Transformando Indústrias e Profissões

Vivemos na era dos dados, um período marcado pela abundância de informações e pela capacidade crescente de utilizá-las para resolver problemas e impulsionar inovações. Em diferentes setores, desde a saúde até os negócios, o uso estratégico de grandes volumes de dados está redefinindo como decisões são tomadas, processos são otimizados e oportunidades são exploradas. Dados, muitas vezes considerados o "novo petróleo", têm se tornado o principal ativo de empresas e instituições, permitindo avanços que eram inimagináveis há poucas décadas.

> Dados são o novo petróleo: extrair, processar, distribuir.

Veja abaixo alguns exemplos de como o uso adequado dos dados pode beneficiar profissões:

1. **Medicina: Diagnóstico Preditivo e Personalizado**

   Na medicina, o uso de dados permite diagnósticos mais rápidos e precisos. Por exemplo, sistemas baseados em inteligência artificial analisam exames de imagem, como ressonâncias magnéticas e tomografias, para detectar anomalias que indicam doenças como câncer. Além disso, hospitais utilizam dados históricos de pacientes para prever complicações pós-cirúrgicas e planejar intervenções. O uso de *Big Data* também possibilita o desenvolvimento de tratamentos personalizados, levando em conta fatores genéticos, históricos médicos e estilo de vida. Por exemplo, um paciente com diabetes pode receber um plano de cuidados ajustado em tempo real, com base em dados coletados por dispositivos vestíveis. Esse monitoramento contínuo melhora a qualidade de vida do paciente e reduz custos hospitalares. Além disso, grandes volumes de dados epidemiológicos ajudam a prever surtos de doenças e a implementar políticas públicas de saúde mais eficazes.

2. **Advocacia: Análise de Precedentes e Automação de Processos**

   Na advocacia, o uso de dados está transformando a forma como os advogados conduzem seus casos. Por exemplo, plataformas de análise jurídica usam dados de milhares de processos para identificar padrões em decisões judiciais. Isso permite que os advogados prevejam com maior precisão o resultado provável de um caso e ajustem suas estratégias. Além disso, ferramentas automatizadas analisam contratos e identificam cláusulas potencialmente problemáticas, economizando horas de revisão manual. No setor corporativo, dados ajudam a monitorar o cumprimento de normas regulatórias, reduzindo o risco de multas. Em escritórios de advocacia, relatórios de desempenho baseados em dados permitem identificar áreas de melhoria, como tempo médio de resolução de casos ou taxas de sucesso. Essas inovações permitem que advogados foquem em atividades estratégicas, deixando tarefas repetitivas para algoritmos.

3. **Engenharia: Monitoramento de Infraestruturas Críticas**

   Na engenharia, sensores instalados em estruturas como pontes, barragens e edifícios geram dados em tempo real sobre condições ambientais e estruturais. Por exemplo, em uma ponte, sensores podem monitorar vibrações, tensões e temperaturas, identificando padrões que indicam desgaste ou risco de colapso. Esses dados são analisados para prever a necessidade de manutenção, evitando falhas catastróficas. Além disso, durante a construção de grandes obras, dados coletados de máquinas e trabalhadores ajudam a otimizar cronogramas e reduzir desperdícios. Em projetos sustentáveis, informações sobre consumo energético e emissão de carbono orientam decisões que minimizam impactos ambientais. Por fim, simulações baseadas em dados históricos permitem que engenheiros testem diferentes cenários antes de implementar alterações, aumentando a segurança e a eficiência.

## A Indústria dos Dados

Em termos simples, dados são informações obtidas em qualquer forma e sobre qualquer assunto. Geramos dados nas nossas atividades diárias. Por exemplo: a sua geolocalização ao longo do dia. Esses dados só têm valor se forem monitorados, capturados e analisados. Por isso, muitos negócios capturam, compilam e rastreiam um volume cada vez maior de dados. Esses negócios esperam obter informações importantes sobre seus clientes que gerem *insights* que ajudem a melhorar a performance em um mercado cada vez mais competitivo e dinâmico.

Existe uma indústria inteira que se baseia em dados: **F**acebook, **A**pple, **A**mazon, **N**etflix, **G**oogle (**FAANG**). Para as empresas **FAANG**, os dados sustentam todo o modelo de negócio.

Sem os seus dados, muitos avanços tecnológicos e facilidades que temos hoje não seriam possíveis. Veja como muitas indústrias utilizam seus dados:

1. **E-commerce**

   - **Como utiliza os dados**:

     **Recomendações personalizadas**: plataformas como Amazon e Mercado Livre analisam o histórico de navegação e compras dos clientes para sugerir produtos relevantes.

     **Gestão de estoque**: utilizam dados de vendas e sazonalidade para prever demanda e otimizar o estoque.

     **Marketing direcionado**: segmentam os clientes com base em suas preferências, enviando promoções e anúncios específicos.

     **Logística**: otimizam rotas de entrega e reduzem custos logísticos usando análises de dados em tempo real.

2. **Finanças e Bancos**

   - **Como utilizam os dados**:

     **Análise de risco**: usam dados financeiros e históricos de crédito para calcular a probabilidade de inadimplência.

     **Detecção de fraudes**: monitoram transações em tempo real para identificar padrões suspeitos e prevenir fraudes.

     **Ofertas personalizadas**: criam produtos financeiros sob medida com base no perfil e comportamento do cliente.

     ***Trading* algorítmico**: aplicam análises de dados e aprendizado de máquina para tomar decisões de compra e venda no mercado financeiro em frações de segundo.

3. **Indústria do Entretenimento e *Streaming***

   - **Como utiliza os dados**:

     **Recomendações de conteúdo**: plataformas como Netflix e Spotify analisam o comportamento do usuário (o que assistem/ouvem, avaliações, tempo de visualização) para sugerir filmes, séries e músicas.

     **Produção de conteúdo original**: usam dados de popularidade para decidir em quais tipos de conteúdos investir (ex.: séries mais vistas em um gênero).

     **Otimização de entrega**: monitoram a performance de seus servidores e ajustam a qualidade do *streaming* em tempo real com base na largura de banda disponível.

     **Análise de tendências**:identificam novos gostos e padrões para explorar mercados emergentes.

4. **Transporte e Logística**

   - **Como utilizam os dados**:

     **Rotas otimizadas**: empresas como FedEx e Uber utilizam dados de tráfego e localização para calcular as rotas mais eficientes, economizando tempo e combustível.

     **Gestão de frota**: monitoram a manutenção de veículos e o consumo de combustível em tempo real para reduzir custos.

     **Previsão de demanda**: analisam padrões históricos de movimentação para ajustar a oferta de veículos ou otimizar os centros de distribuição.

     **Experiência do cliente**: coletam *feedback* e analisam dados de viagens para melhorar o serviço e aumentar a satisfação do usuário.

Com tantos exemplos da utilização de dados em profissões e indústrias, fica claro que no mundo dos negócios, pesquisa e desenvolvimento, dados são de extrema importância. Mas como obtemos esses dados? Como organizamos e indexamos esses dados? Essas são algumas das perguntas que serão respondidas ao longo da apostila.

## Dados Estruturados e Não Estruturados: O Alicerce da Era da Informação

Os dados estão no centro da transformação digital que permeia o mundo moderno. Desde os registros financeiros em uma planilha até as imagens de satélite que monitoram mudanças climáticas, o volume e a variedade de informações disponíveis nunca foram tão vastos. Dentro desse cenário, a distinção entre dados estruturados e dados não estruturados se torna essencial para entender como as organizações utilizam informações para gerar *insights* e tomar decisões estratégicas.

Dados estruturados referem-se àquelas informações organizadas em formatos predefinidos, como tabelas e bancos de dados relacionais. Eles são facilmente categorizados e analisados devido à sua organização clara e consistente. Por exemplo, registros de vendas de uma loja, organizados por data, produto e valor, são dados estruturados que podem ser usados para identificar tendências de consumo e planejar promoções.

Por outro lado, os dados não estruturados não seguem um formato fixo, tornando-os mais complexos de organizar e processar. Exemplos incluem e-mails, vídeos, imagens, postagens em redes sociais e relatórios em texto livre. Apesar de sua complexidade, esses dados representam uma mina de ouro de informações valiosas. Um exemplo clássico é a análise de comentários de clientes em redes sociais, que fornece *insights* sobre a percepção da marca e auxilia na criação de estratégias de marketing.

A combinação de dados estruturados e não estruturados oferece às organizações uma visão mais completa de suas operações e mercados. Enquanto os dados estruturados proporcionam precisão e eficiência, os dados não estruturados revelam nuances e padrões ocultos que podem não ser percebidos de outra forma. Juntos, eles formam o alicerce da era da informação, onde o poder de transformar dados em decisões define o sucesso no mundo moderno.

### Exemplos de Dados Estruturados

1. **Registro de Vendas de um E-commerce**

   Um e-commerce mantém registros detalhados de todas as transações realizadas, organizados em tabelas com colunas como data da compra, nome do cliente, ID do produto, quantidade comprada e valor total. Esses dados são armazenados em um banco de dados relacional, permitindo consultas rápidas e análises eficientes. Com base nessas informações, a empresa pode

identificar produtos mais vendidos, sazonalidades nas vendas e ajustar estoques para atender à demanda futura.

2. **Inventário de Estoque de uma Fábrica**

   Uma fábrica registra informações sobre seu estoque em tabelas estruturadas com colunas como ID do item, descrição, quantidade em estoque, localização no armazém e custo por unidade. Esses dados ajudam a gerenciar a produção, garantindo que materiais estejam disponíveis no momento certo. Com o uso de sistemas de gestão baseados em dados estruturados, a fábrica reduz desperdícios, melhora a eficiência operacional e evita atrasos na entrega de produtos ao cliente.

#### Exemplos de Dados Não Estruturados

1. **Postagens em Redes Sociais**

   Postagens em plataformas como Instagram, Facebook ou Twitter são exemplos clássicos de dados não estruturados. Elas incluem texto livre, imagens, vídeos e até interações como curtidas e comentários. Esses dados não seguem um formato fixo e podem variar significativamente de usuário para usuário. Apesar disso, análises avançadas podem identificar padrões, como o sentimento em relação a uma marca ou tendências emergentes. Por exemplo, uma empresa pode usar ferramentas de análise para monitorar menções ao seu nome e ajustar suas campanhas de marketing com base no *feedback* do público.

2. **Gravações de Chamadas em Centros de Atendimento ao Cliente**

   As chamadas gravadas em *call centers* contêm informações valiosas, mas estão em formato não estruturado, pois consistem em áudio que precisa ser processado para extrair *insights*. Empresas podem utilizar essas gravações para analisar a satisfação do cliente, identificar reclamações recorrentes e avaliar o desempenho dos atendentes. Com o uso de tecnologias como reconhecimento de voz e análise de sentimento, essas interações podem ser transcritas e classificadas, fornecendo dados úteis para melhorar o atendimento e os processos internos.

## A Importância do Engenheiro de Dados na Era da Informação

Vivemos em um mundo onde os dados estão por toda parte. Eles ajudam empresas a tomar decisões melhores, permitem diagnósticos médicos mais precisos, melhoram os serviços de transporte e até influenciam o que assistimos ou compramos online. Mas, para que tudo isso funcione, existe um profissional fundamental: o **engenheiro de dados**.

O engenheiro de dados é como o "arquiteto" de uma grande rede de informações. Ele projeta, constrói e mantém os sistemas que coletam, organizam e disponibilizam dados para serem analisados. Esses

sistemas incluem conceitos-chave como *data pipeline*, *data lake* e *data warehouse*, que são essenciais para transformar dados brutos em *insights* úteis.

**Por que Isso é Importante?**

Para médicos, advogados, administradores de empresas e profissionais de outras indústrias, o trabalho do engenheiro de dados impacta diretamente o dia a dia.

O engenheiro de dados, portanto, não é apenas alguém que lida com tecnologia, mas um facilitador que conecta dados a soluções práticas e estratégicas. Ele garante que informações complexas se tornem ferramentas acessíveis, ajudando profissionais de diversas áreas a prosperar na era digital.

## O que você aprendeu

- Dados é o "novo petróleo".
- Uso estratégico dos dados em profissões.
- Dados Estruturados e Não Estruturados.
- O Papel do Engenheiro de Dados.
- O que é a Indústria dos Dados
- A importância de transformar dados brutos em informações úteis e a demanda por profissionais qualificados.

## Novas Palavras-Chave

- **Big Data**

  A expressão *Big Data* foi primeiramente empregada por John Mashey para se referir ao processamento e avaliação de grandes volumes de dados. O termo *Big Data* se tornou popular no inicio da década de 2000, quando Doug Laney estabeleceu o conceito dos "3V's": volume, velocidade e variedade. Segundo essa definição, *Big Data* se refere a um volume crescente de dados que se torna complexo ou até mesmo inviável de ser manipulado pelos métodos convencionais.

- **Data Pipeline**

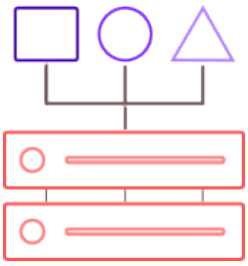

**Figure 1:** data pipeline

Imagine um tubo que transporta água de um rio até uma torneira. O *data pipeline* funciona de forma semelhante, mas em vez de água, ele transporta dados. Ele pega informações de várias fontes, como sistemas de vendas, aplicativos ou sensores, e as organiza para que possam ser usadas. O engenheiro de dados garante que esse fluxo seja eficiente, confiável e seguro, como um encanador cuida da tubulação para evitar vazamentos.

- **Data Lake**

**Figure 2:** data lake

O *data lake* é como um grande lago onde você pode armazenar qualquer tipo de dado, seja estruturado ou não. Pense no *data lake* como um depósito onde tudo é guardado, desde planilhas organizadas até vídeos e imagens. Ele é muito útil porque permite que empresas armazenem dados sem a necessidade de organizá-los imediatamente. Porém, se esse lago não for bem gerenciado, pode virar um "pântano" onde nada é encontrado. É aí que entra o engenheiro de dados, que organiza e mantém o acesso a essas informações.

- **Data Warehouse**

**Figure 3:** data warehouse

Enquanto o *data lake* guarda tudo, o *data warehouse* é mais como um supermercado bem organizado. Ele contém apenas os dados mais importantes e os organiza de maneira que sejam fáceis de acessar e analisar. Por exemplo, uma empresa pode usar um *data warehouse* para visualizar suas vendas semanais ou o desempenho de diferentes filiais. O engenheiro de dados transforma os dados brutos do *data lake* em informações claras e úteis para serem armazenadas no *data warehouse*.

# O Papel do Engenheiro de Dados

## Qual o papel do Engenheiro de Dados?

Quando falamos de **Engenharia de Dados**, sempre aparecem as perguntas:

- O que faz o Engenheiro de Dados?
- As funções do Engenheiro de Dados não são iguais às do Cientista de Dados?

Os papéis de Engenheiros de Dados e Cientistas de Dados são complementares no ecossistema de dados, contudo, suas funções e obrigações são diferentes.

---

**Engenheiros de Dados** são responsáveis pela movimentação dos dados de um sistema para outro. Em resumo o Engenheiro de Dados:

- Extrai dados (**E***xtract*)
- Transforma dados (**T***ransform*)
- Carrega e disponibiliza os dados em um banco de dados (**L***oad*)

---

Quando se fala em Engenharia de dados a sigla **ETL** (***E****xtract*, ***T****ransform*, ***L****oad*) sempre aparece. Essa sigla resume de forma bem simples o papel do Engenheiro de Dados.

Para aprofundar nosso entendimento sobre Engenharia de Dados e diferenciá-la da Ciência de Dados, apresentaremos a seguir uma visão mais detalhada dessas profissões e suas distinções.

## Engenheiro de Dados

---

**Figure 4:** engenheiro de dados

- Consumir e Armazenar Dados.
- Configurar Banco de Dados.
- Construir *Data Pipelines*.
- Habilidade com *Softwares*.

**Objetivo Principal**: implementação, conservação e aperfeiçoamento da infraestrutura e dos **canais de dados** (*data pipelines*).

---

**Principais Atribuições do Engenheiro de Dados**

1. **Coleta e Integração de Dados**:
   - Desenvolver e administrar *pipelines* de ETL/ELT para recolher informações de diversas origens e integrá-las em sistemas centralizados, como *data warehouses* ou *data lakes*.
2. **Design e Arquitetura**:
   - Criar estruturas flexíveis e eficazes para guardar e tratar grandes quantidades de dados (*Big Data*).
3. **Otimização de Desempenho**:
   - Otimizar a eficiência dos sistemas de informação, melhorando as consultas e garantindo um acesso rápido e de baixa latência.
4. **Governança e Segurança**:
   - Assegurar que as informações sejam guardadas e manipuladas de maneira segura, seguindo as normas e regulamentos. No Brasil o Engenheiro de Dados é obrigado a seguir a Lei Geral de Proteção de Dados Pessoais (LGPD).

5. **Automação e Expansão**:
    - Desenvolver soluções que possibilitem o aumento sustentável do volume de dados e a capacidade de expansão dos sistemas.
6. **Recursos e Tecnologias**:
    - Utilizar ferramentas como **Apache Spark**, **Hadoop**, **Nifi**, **Kafka**, bases de dados **SQL**/**NoSQL**, ferramentas de armazenamento em nuvem, entre outros.

**Descrição de Competências do Engenheiro de Dados**

- Programação complexa (por exemplo, **Python**, **Java**, **Scala**).
- Conhecimento em bancos de dados SQL/NoSQL e sistemas de distribuição.
- **DevOps**.

## Cientista de Dados

---

**Figure 5:** cientista de dados

- Exploração de Dados.
- Acessa Banco de Dados.
- Utiliza *Data Pipelines* na análise de dados.
- Forte Habilidade Analítica.

**Objetivo Principal**: análise, modelagem estatística e extração de informações/percepções (*insights*) a partir dos dados.

---

**Principais Atribuições do Cientista de Dados**

1. **Análise e Exploração de Dados**:
    - Analisar conjuntos de informações para reconhecer padrões, tendências e irregularidades.
2. **Modelagem e Programação**:
    - Desenvolver, capacitar e analisar modelos estatísticos ou de aprendizado de máquina para solucionar desafios empresariais.
3. **Análise de Dados**:
    - Desenvolver relatórios, gráficos e painéis que forneçam percepções às partes interessadas.
4. **Decisão embasada em Dados**:
    - Converter descobertas analíticas em sugestões práticas para solucionar questões organizacionais.
5. **Investigação e Inovação**:
    - Investigar novos métodos analíticos e melhorar o estado da arte no campo.
6. **Tecnologias e Ferramentas**:
    - Utilizar ferramentas como **TensorFlow**, **PyTorch**, **Scikit-Learn**, **Pandas**, além de softwares de visualização como **Tableau**, **Power BI** ou **Matplotlib**.

**Descrição de Competências do Cientista de Dados**

- Conhecimento sólido em Estatística e Matemática.
- Proficiência em programação (ex.: **Python**, **R**, etc).
- Experiência em *machine learning* e *deep learning*.
- Entendimento de negócio para contextualizar análises.

## Engenheiro de Dados vs Cientista de Dados

Vamos resumir o que vimos até agora sobre as diferenças entre Engenheiros de Dados e Cientistas de Dados na tabela abaixo.

| Aspecto | Engenheiro de Dados | Cientista de Dados |
|---|---|---|
| **Objetivo Principal** | Gerir infraestrutura e *pipelines* de dados | Analisar e modelar dados |
| **Foco** | Sistemas e arquitetura | *Insights* e soluções analíticas |
| **Ferramentas Comuns** | Apache Spark, Kafka, Hadoop, SQL | scikit-learn, TensorFlow, Tableau |
| **Perfil Técnico** | Engenharia de software | Matemática, Estatística, ML |
| **Atuação no Ciclo de Dados** | Garantir disponibilidade e qualidade dos dados | Explorar e gerar valor a partir dos dados |

Baseado no que vimos até agora, fica claro que o Engenheiro de Dados age nos bastidores. Sem o Engenheiro de Dados os canais de dados (*data pipeline*) utilizados pelos Cientistas de Dados e outros profissionais não seria possível, em muitos casos, devido ao volume e complexidade da obtenção, manutenção e disposição dos dados.

## Impacto do Engenheiro de Dados nas Organizações

O profissional de engenharia de dados é uma das bases essenciais na era da informação. O seu trabalho, frequentemente executado nos bastidores, assegura a conversão de dados brutos em recursos estratégicos para empresas e entidades de todos os portes. Este profissional tem impacto em várias áreas, desde *startups* inovadoras até grandes corporações globais, auxiliando em decisões mais bem fundamentadas, processos aprimorados e inovação constante.

### Decisões Baseadas em Dados

Em uma sociedade cada vez mais orientada por dados, as decisões fundamentadas em fatos prevalecem sobre as baseadas apenas na intuição. O profissional de engenharia de dados assegura que os responsáveis tenham acesso a dados precisos, atualizados e estruturados. Por exemplo, numa cadeia de lojas, as informações recolhidas sobre vendas, inventário e comportamento do cliente são processadas e convertidas em relatórios claros e práticos. Esses relatórios auxiliam os administradores a reconhecer padrões, ajustar inventários e elaborar promoções sazonais, potencializando a eficácia e os ganhos.

**Otimização de Processos Operacionais** O engenheiro de dados também é essencial para a eficiência operacional. Ele cria sistemas que combinam informações de diversas fontes, removendo

redundâncias e inconsistências. Por exemplo, num hospital, um engenheiro de dados tem a capacidade de desenvolver *pipelines* que unem informações de pacientes, resultados de exames e inventários de medicamentos em tempo real. Não só aprimora a assistência ao paciente, como também diminui os gastos operacionais ao prevenir desperdícios e atrasos.

**Criação de Vantagem Competitiva** Em mercados competitivos, o acesso ágil e exato a informações pode representar a distinção entre êxito e insucesso. Um especialista em engenharia de dados auxilia as organizações a se sobressaírem ao oferecer a fundação para análises sofisticadas e modelagem preditiva. Em uma empresa de transporte, dados históricos e em tempo real sobre tráfego, manutenção de veículos e preferências dos clientes podem ser utilizados para otimizar rotas e prever demandas, melhorando a experiência do cliente e reduzindo custos operacionais.

**Facilitador da Inovação** O trabalho do engenheiro de dados permite que as organizações explorem novas oportunidades. Ao estabelecer *data lakes*, que armazenam grandes quantidades de dados não estruturados, possibilita que cientistas de dados e outros especialistas executem análises detalhadas e testem novas estratégias. Por exemplo, em uma companhia tecnológica, essas informações podem ser empregadas para criar algoritmos de inteligência artificial que aprimoram a personalização de produtos ou serviços.

**Suporte à Escalabilidade e Sustentabilidade** Com o aumento exponencial de dados, as empresas necessitam de sistemas que possam ser expandidos e sustentáveis. O profissional de engenharia de dados cria sistemas que não só suportam grandes volumes de dados, mas também asseguram que esses dados sejam tratados de maneira eficaz. Em um banco, isso pode envolver o desenvolvimento de sistemas que rastreiam transações em tempo real para evitar fraudes, assegurando a segurança e a fiabilidade dos serviços prestados.

**Diversidade de Impacto em Diferentes Indústrias** O impacto do engenheiro de dados não se limita a um único setor. Na área da saúde, ele permite diagnósticos mais ágeis e exatos. Na profissão jurídica, organiza grandes quantidades de documentos legais para simplificar a avaliação de casos. Em pequenas empresas, auxilia na conversão de dados básicos de vendas em percepções úteis para o crescimento. Esta variedade evidencia a flexibilidade e adaptabilidade do engenheiro de dados às demandas particulares de cada instituição.

Em resumo, o engenheiro de dados desempenha um papel essencial na transformação digital das organizações. Ele tem a tarefa de assegurar que os dados não sejam somente guardados, mas também empregados de forma eficaz e estratégica. A sua intervenção promove a tomada de decisões, a inovação e a competitividade, posicionando as empresas em um lugar de destaque na era da informação.

Seja em corporações de grande porte ou pequenas empresas, a relevância deste profissional é crucial para o êxito da organização.

## Exemplos de Projetos de Engenharia de Dados

### Exemplo 1: *Pipeline* para Atualização de Dados de Vendas

Uma loja online coleta dados de vendas diariamente. Esse *data pipeline* pega as informações de diferentes sistemas (como o site, caixas e aplicativos) e organiza tudo em banco de dados central para relatórios.

**Responsabilidades do Engenheiro de Dados:**

- Criar um processo automatizado para coletar os dados das fontes (ETL: extração, transformação e carregamento).
- Limpar os dados para corrigir erros, como preços ou datas inconsistentes.
- Garantir que os dados sejam armazenados em um banco de dados ou *data warehouse* de fácil acesso para as equipes de negócios gerarem relatórios de desempenho.

---

### Exemplo 2: *Pipeline* de Monitoramento de Tráfego de Site

Um portal de notícias quer analisar o comportamento dos visitantes no site, como páginas mais acessadas ou tempo gasto em artigos. O *data pipeline* coleta e processa esses dados em tempo real.

**Responsabilidades do Engenheiro de Dados:**

- Configurar sistemas que capturem dados de navegação no site e os enviem para um serviço de armazenamento.
- Criar um mecanismo para transformar os dados brutos em métricas úteis, como o número de visitas por hora.
- Garantir que as informações sejam atualizadas continuamente e estejam disponíveis para os analistas em ferramentas de visualização como Power BI ou Tableau.

---

**Exemplo 3: *Pipeline* para Dados de Sensores de uma Fábrica**

Uma fábrica usa sensores para monitorar a temperatura das máquinas. O *data pipeline* coleta os dados dos sensores e alerta a equipe em caso de superaquecimento.

**Responsabilidades do Engenheiro de Dados:**

- Integrar os sensores ao sistema central, garantindo que os dados sejam transmitidos em tempo real.
- Criar um processo que filtre e analise os dados, detectando padrões ou problemas como altas temperaturas.
- Configurar alertas automáticos para notificar os responsáveis caso os dados indiquem possíveis falhas, ajudando na manutenção preventiva.

## O que você aprendeu

- Responsabilidades e competências do engenheiro de dados na construção de infraestruturas robustas e eficientes.
- Diferenças entre engenharia de dados e ciência de dados e como essas áreas se complementam.
- Impacto do engenheiro de dados nas organizações e indústrias, promovendo decisões estratégicas e inovação baseada em dados.
- Relevância desse profissional como base no universo da análise e gestão de dados.

## Conceitos Essenciais

### O que é Data Pipeline?

Um *pipeline* de dados é um procedimento onde os dados brutos são obtidos de diversas fontes, processados e posteriormente armazenados em banco de dados, como em um *data lake* ou em um *data warehouse*, para posterior análise.

> **Pipeline**: palavra da língua inglesa que pode significar encanamento, gasoduto, oleoduto, etc, de acordo com o contexto. Exemplos: *water pipeline* (encanamento de água), *oil pipeline* (oleoduto), etc.

Uma analogia para o *data pipeline* é o *water pipeline*, ou encanamento de água. Para termos água em casa, não conectamos nossas torneiras diretamente nos rios ou lagos. A água que bebemos ou que utilizamos para lavar nossas roupas é obtida através de um processo que é dividido em três etapas:

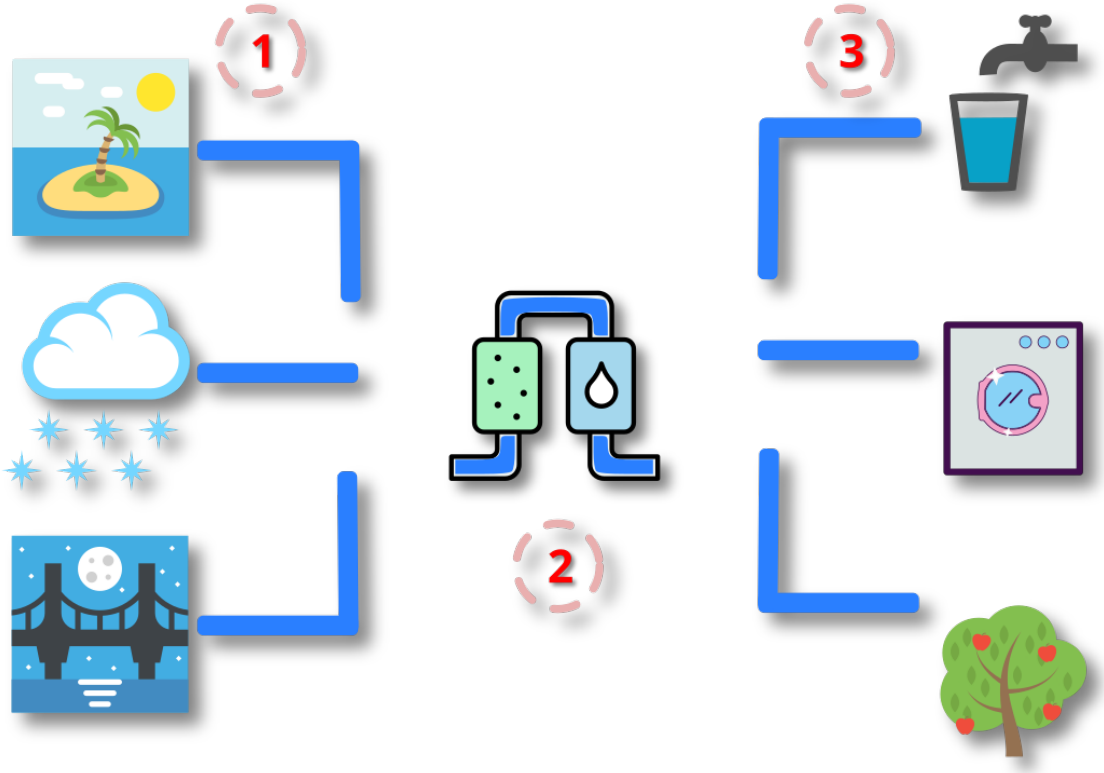


**Figure 6:** water pipeline

1. Captação da água

2. Tratamento da água
3. Disponibilização da água

A captação da água ocorre nas fontes de água: nos rios e lagos, da chuva (através de armazenamento), e até no mar (com tecnologia específica). Toda a água obtida nas fontes é transportada até um centro de tratamento onde se tornará água potável através de diversos processos de purificação. A disponibilização da água ocorre nas nossas casas, na indústria ou mesmo em fazendas.

Para garantir o fornecimento contínuo de água o *water pipeline* tem que funcionar na sua totalidade:

- **Captação**: as fontes de água devem fornecer quantidade suficiente de água de acordo com a demanda. A água própria para o consumo depende de uma fonte de água adequada, sem poluentes pesados, fácil de purificar e com disponibilidade ao longo prazo.
- **Tratamento da água**: tratamento da água é um processo específico que depende da fonte de água. Por exemplo, o tratamento da água vinda de um poço profundo é mais simples do que o tratamento da água de um rio com intensa circulação de embarcações, que podem causar poluição.
- **Disponibilização da água**: o *water pipeline* deve ser capaz de disponibilizar a água onde haja demanda. As demandas mais comuns ocorrem na indústria, na agricultura, na pecuária e nas nossas casas. O transporte eficiente da água, na pressão correta e isolamento são necessários para garantir o fornecimento contínuo.

Da mesma forma que o *water pipeline* necessita de etapas bem específicas e implementadas de maneira adequada, o *data pipeline* possui etapas específicas que também devem ser implementadas adequadamente para garantir a disponibilidade contínua de dados.

Na prática, um *data pipeline* é uma sequência de processos que captura, transforma, armazena e disponibiliza dados para que possam ser usados em análises ou aplicações. Ele é composto de três etapas principais:

1. **Coleta de dados**: os dados podem vir de várias fontes, como bancos de dados, sensores, sites ou até planilhas. Exemplos:

    a. **Aplicativos de celular**: um aplicativo de transporte como o *Uber* coleta dados sobre a localização dos motoristas e passageiros em tempo real, além de registrar informações como destinos e horários das corridas.

    b. **Sistemas de e-commerce**: plataformas como a *Amazon* registram dados das compras realizadas, como produtos adquiridos, preferências dos usuários e métodos de pagamento usados.

   c. **Sensores indústriais**: em uma fábrica, sensores instalados nas máquinas coletam dados sobre temperatura, vibração e desempenho para monitorar e prevenir falhas.

2. **Transformação dos dados**: nem todos os dados chegam no formato certo para uso. Alguns podem estar desorganizados, incompletos ou precisam de ajustes: limpar os dados, padronizar informações e os organizar no formato necessário. Exemplos:

   a. **Remoção de duplicatas**: em um banco de dados de clientes, se o mesmo nome e e-mail aparecem várias vezes, as duplicatas são removidas para garantir que cada cliente seja contado apenas uma vez.

   b. **Conversão de formatos**: transformar datas de diferentes formatos, como "14-01-2025" e "2025/01/14", para um formato padrão, como "14 de janeiro de 2025".

   c. **Categorização de dados**: em uma pesquisa de satisfação, respostas como "Ótimo", "Muito bom" e "Excelente" podem ser agrupadas em uma única categoria chamada "Satisfação alta".

3. **Armazenamento e disponibilidade**: depois de transformados, os dados são armazenados em um local seguro, como um banco de dados ou um *data warehouse*, ou enviados diretamente para um sistema que os utilizará, como um painel de controle que mostra gráficos em tempo real. Exemplos:

   a. **Armazenamento em bancos de dados**: dados coletados de um site de e-commerce, como detalhes de pedidos e informações de clientes, são armazenados em um banco de dados relacional para consultas e relatórios futuros.

   b. **Envio para dashboards**: dados de sensores de uma fábrica são processados e enviados para um painel de controle, onde os gestores podem monitorar métricas como temperatura e produtividade em tempo real.

   c. **Armazenamento em data warehouses**: grandes volumes de dados históricos de uma empresa são armazenados em um *data warehouse* para análises avançadas, como identificar tendências de vendas ao longo dos anos.

O objetivo principal de um *data pipeline* é garantir que os dados certos estejam disponíveis no momento certo e no formato adequado para quem precisa usá-los. Ele é essencial para empresas que tomam decisões baseadas em dados, ajudando a integrar informações de várias áreas, como vendas, marketing e operações.

Assim, o data pipeline automatiza e organiza o fluxo de dados, economizando tempo e minimizando erros que poderiam ocorrer se tudo fosse feito manualmente.

**Data Pipeline e a Engenharia de Dados**

*Data pipeline* pode assumir formas diferentes de acordo com a aplicação desses dados. Vamos tomar como exemplo um *data pipeline* com o objetivo de fornecer dados para um cientista de dados determinar tendências no preço de automóveis usados.

**Data Pipeline:**

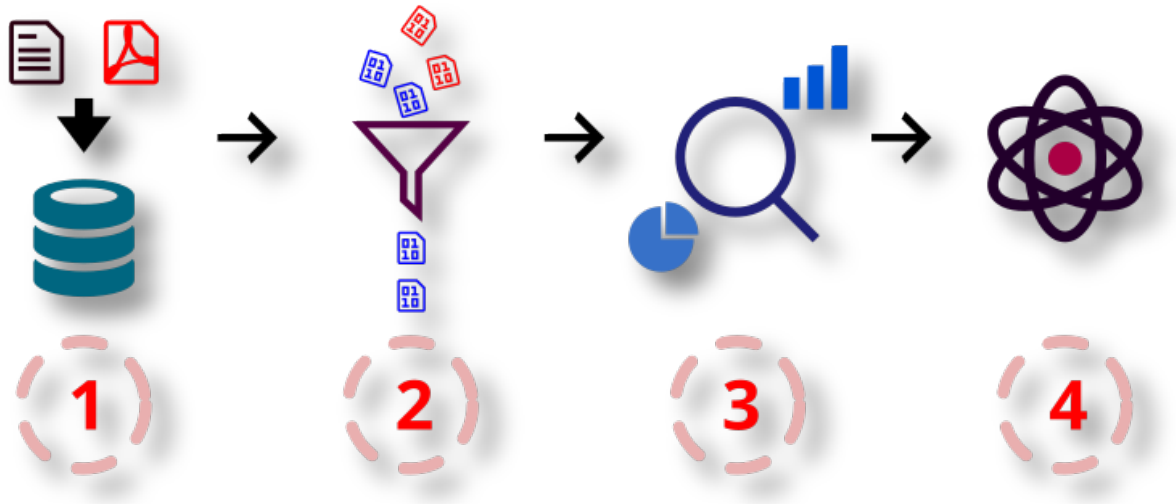


**Figure 7:** data pipeline completo.

1. Obtenção de Dados e Armazenamento
2. Preparação dos Dados
3. Exploração e Visualização
4. Experimento e Predição

*Data pipeline* será dividido em quatro etapas:

1. **Obtenção de Dados e Armazenamento**

   Nesta etapa, o objetivo é coletar dados relevantes sobre automóveis usados e armazená-los em uma infraestrutura apropriada.

   a. **Fontes de dados**:

   - Sites de vendas de automóveis usados, como OLX ou Webmotors.
   - Bancos de dados de concessionárias.
   - APIs públicas ou privadas que forneçam informações sobre preços, modelos e especificações.

b. **Tipo de dados coletados**:

- Dados estruturados: tabela com informações como modelo, ano, quilometragem, preço, localização, etc.
- Dados não estruturados: descrições textuais ou imagens dos automóveis.

c. **Armazenamento**:

- Um *data lake* pode ser utilizado para armazenar grandes volumes de dados brutos.
- Para dados mais organizados, como tabelas com atributos específicos, um banco de dados relacional (ex.: MySQL ou PostgreSQL) pode ser usado.

2. **Preparação dos Dados**

Os dados coletados precisam ser limpos e transformados antes de serem analisados.

a. **Tarefas de limpeza**:

- Remover dados duplicados, como anúncios repetidos de um mesmo carro.
- Tratar valores ausentes (ex.: substituir preços faltantes pela média do mercado ou descartar registros incompletos).

b. **Transformações**:

- Converter unidades (ex.: milhas para quilômetros).
- Normalizar os preços para uma moeda comum, se houver dados de diferentes regiões.
- Criar novas variáveis, como a idade do carro (ano atual menos o ano de fabricação).

c. **Ferramentas**:

- Processos ETL (Extract, Transform, Load) utilizando ferramentas como Python (pandas) ou ferramentas dedicadas como Apache NiFi.

3. **Exploração e Visualização**

Nesta etapa, os dados são analisados e visualizados para identificar padrões e *insights* iniciais.

a. **Exploração dos dados**:

- Observar a distribuição dos preços dos automóveis com histogramas.
- Identificar tendências sazonais ou regionais nos preços (ex.: carros mais baratos em determinada época do ano ou localidade).
- Detectar *outliers*, como preços muito acima ou abaixo da média.

b. **Visualização**:

- Gráficos de dispersão para correlacionar preço com idade ou quilometragem.
- Mapas para mostrar a distribuição geográfica dos preços.

c. **Ferramentas**:

- Python (matplotlib, seaborn, plotly).
- Ferramentas de BI, como Tableau ou Power BI.

4. **Experimento e Predição**

   Os dados preparados são utilizados para treinar modelos de aprendizado de máquina que preveem tendências de preços.

   a. **Modelos treinados**:

   - Modelos de regressão para prever o preço de um carro com base em variáveis como idade, quilometragem, e localização.
   - Algoritmos mais avançados, como *Random Forest*, para capturar relações não lineares nos dados.

   b. **Validação**:

   - Dividir os dados em conjuntos de treino e teste para avaliar a precisão do modelo.
   - Ajustar hiperparâmetros para melhorar o desempenho.

   c. **Predição**:

   - Usar o modelo treinado para prever tendências futuras, como aumento ou queda nos preços médios em determinado período ou região.

   d. **Ferramentas**:

   - Python (scikit-learn, TensorFlow).
   - Plataformas de machine learning como AWS SageMaker ou Google Vertex AI.

**Então, qual dessas etapas é responsabilidade do Engenheiro de Dados?**

As responsabilidades do engenheiro de dados estão concentradas principalmente nas etapas iniciais e parcialmente na terceira etapa, embora a separação exata das tarefas possa variar dependendo da equipe e do projeto. Vamos analisar em detalhes:

1. *Obtenção de Dados e Armazenamento*

   Responsabilidade principal do engenheiro de dados.

   **Tarefas típicas**:

- Identificar e integrar fontes de dados (APIs, bancos de dados, arquivos CSV, etc.).
- Configurar fluxos automatizados para extrair dados de diferentes fontes.
- Criar e gerenciar infraestrutura de armazenamento, como data lakes (ex.: AWS S3, Azure Blob Storage) ou bancos de dados relacionais e não relacionais.
- Garantir a escalabilidade e eficiência da arquitetura de ingestão de dados.

2. **Preparação dos Dados**

   Responsabilidade principal do engenheiro de dados.

   **Tarefas típicas**:

   - Implementar processos de ETL (Extração, Transformação e Carregamento):
   - Limpeza básica dos dados (ex.: remover duplicatas, padronizar formatos).
   - Transformações iniciais (ex.: normalizar dados, criar tabelas intermediárias).
   - Carregar os dados tratados no ambiente de análise.
   - Automatizar esses processos com ferramentas como Apache Airflow, Apache Spark ou scripts personalizados em Python/SQL.
   - Garantir a qualidade e integridade dos dados ao longo do pipeline.

3. Exploração e Visualização

   Responsabilidade compartilhada entre engenheiro de dados e cientista de dados.

   **Contribuição do engenheiro de dados**:

   - Criar tabelas ou *views* otimizadas no banco de dados para facilitar análises exploratórias.
   - Implementar agregações ou cálculos pré-processados para melhorar a eficiência das análises.
   - Garantir que as ferramentas de visualização (ex.: Tableau, Power BI) estejam integradas à infraestrutura de dados.

   **Contribuição principal do cientista de dados**:

   - Analisar os dados para identificar padrões ou *insights* específicos.
   - Criar visualizações personalizadas para apresentações ou relatórios.

4. **Experimento e Predição**

   Responsabilidade principal do cientista de dados.

   **Papel secundário do engenheiro de dados**:

   - Fornecer acesso eficiente e confiável aos dados necessários para treinamento de modelos.
   - Garantir que os dados usados para experimentos estejam limpos, atualizados e disponíveis no formato esperado.

- Colaborar para integrar os modelos em um ambiente de produção (caso o cientista de dados desenvolva os modelos).

**Resumo das Responsabilidades do Engenheiro de Dados**

- **Principais responsabilidades**: Etapas 1 e 2 (Obtenção de Dados e Armazenamento e Preparação dos Dados).
- **Responsabilidade parcial**: Suporte na etapa 3 (Exploração e Visualização).
- **Responsabilidade secundária**: Garantir que a etapa 4 (Experimento e Predição) tenha suporte técnico adequado para uso eficiente dos dados.

O engenheiro de dados desempenha um papel essencial na criação de uma base sólida para que o cientista de dados possa se concentrar em análises e previsões.

## *Data Lake* vs *Data Warehouse*: Uma Visão de *Big Data*

### O que é *Big Data*?

***Big Data*** refere-se a grandes volumes de dados gerados continuamente por diversas fontes, que são difíceis de gerenciar, processar e analisar usando métodos e ferramentas tradicionais. O conceito é definido por três características principais, conhecidas como os **3Vs** (Volume, Velocidade e Variedade), às vezes estendidos para **5Vs**, incluindo Veracidade e Valor:

1. **Volume:** representa a quantidade massiva de dados gerados, como transações financeiras, interações em redes sociais, logs de servidores, dados de sensores IoT (internet das coisas), e mais.
2. **Velocidade:** refere-se à rapidez com que os dados são gerados e precisam ser processados. Exemplos incluem transmissões em tempo real, como dados de GPS ou transmissões de vídeo ao vivo.
3. **Variedade:** diz respeito aos diferentes formatos de dados, incluindo estruturados (tabelas), semiestruturados (JSON, XML) e não estruturados (imagens, vídeos, áudio).
4. **Veracidade:** trata da confiabilidade e precisão dos dados, considerando que informações podem ser inconsistentes, duplicadas ou erradas.
5. **Valor:** o objetivo final do *Big Data* é transformar esses dados em *insights* acionáveis para resolver problemas ou gerar oportunidades.

*Big Data* não é apenas sobre o volume, mas também sobre a capacidade de extrair informações úteis desse grande conjunto de dados. Ele é usado em diversas áreas, como análise de mercado, person-

alização de experiências de usuários, manutenção preditiva em indústrias e até no diagnóstico de doenças.

Para lidar com Big Data, tecnologias como Hadoop, Apache Spark e bancos de dados distribuídos foram criadas, permitindo o armazenamento, processamento e análise de dados em larga escala de forma eficiente e escalável.

**O que é um *Data Lake*?**

Um *data lake* é um repositório centralizado que armazena grandes volumes de dados em seu formato original, ou seja, sem pré-processamento ou organização rígida. Ele foi projetado para lidar com as características de *Big Data*, incluindo dados estruturados (como tabelas SQL), semiestruturados (como arquivos JSON ou XML) e não estruturados (como imagens, vídeos e documentos).

1. **Características principais**:
    a. **Armazenamento flexível**: os dados são armazenados em blocos ou arquivos, sem a necessidade de um esquema pré-definido. Isso torna o *data lake* altamente escalável.
    b. **Alta capacidade de ingestão**: ele permite coletar dados em grande volume e em alta velocidade, ideal para aplicações como IoT e logs de servidores.
    c. **Análises avançadas**: os dados em um *data lake* podem ser utilizados por cientistas de dados para aprendizado de máquina, análises preditivas ou mineração de dados.
2. **Vantagens**:
    a. **Custo acessível**: geralmente usa armazenamento em nuvem, como Amazon S3 ou Azure Data Lake, que é barato para armazenar grandes quantidades de dados.
    b. **Flexibilidade de uso**: os dados podem ser processados posteriormente conforme as necessidades específicas de análise.
3. **Desafios**:
    a. **Qualidade de dados**: sem governança rigorosa, um *data lake* pode se tornar um "*data swamp*" (pântano de dados), onde dados desorganizados se acumulam, dificultando o uso.
    b. *Velocidade de consulta*: dados brutos podem ser mais lentos para análises se não forem preparados ou indexados adequadamente.
4. **Exemplos de ferramentas**:
    - Amazon S3 (armazenamento em nuvem).

- Apache Hadoop (armazenamento distribuído e processamento).
- Azure Data Lake (solução de data lake da Microsoft).

**O que é um *Data Warehouse*?**

Um *data warehouse* é um sistema projetado para análise e geração de relatórios com base em **dados estruturados**. Ele organiza dados provenientes de diferentes fontes em tabelas e esquemas pré-definidos, **otimizando consultas e relatórios** para facilitar a tomada de decisão empresarial.

1. **Características principais**:
   a. **Dados processados**: os dados carregados em um *data warehouse* passam por um processo ETL (Extração, Transformação e Carregamento), garantindo que estejam limpos e organizados.
   b. **Modelagem estruturada**: os dados são organizados em esquemas, permitindo consultas eficientes.
   c. **Foco em relatórios**: ideal para criar *dashboards* e análises que suportam decisões estratégicas.
2. **Vantagens**:
   a. **Desempenho otimizado**: projetado para responder a consultas complexas em alta velocidade.
   b. **Governança rigorosa**: dados seguem regras bem definidas, garantindo consistência e qualidade.
   c. **Segurança e controle**: mais adequado para informações confidenciais, como dados financeiros.
3. **Desafios**:
   a. **Custos mais altos**: infraestrutura e processamento exigem maior investimento, especialmente em soluções corporativas.
   b. **Rigidez**: requer um esquema fixo. Alterações são complexas e podem ser demoradas.
4. **Exemplos de ferramentas**:
   - Amazon Redshift (solução de data warehouse em nuvem da AWS).
   - Google BigQuery (serviço de análise de dados em larga escala).
   - Snowflake (plataforma independente de armazenamento e análise de dados).

**Comparação: *Data Lake* vs *Data Warehouse***

| Aspecto | Data Lake | Data Warehouse |
|---|---|---|
| **Tipo de Dados** | Estruturados, semiestruturados e não estruturados | Apenas estruturados |
| **Processamento** | Dados brutos, processados sob demanda | Dados processados e organizados |
| **Flexibilidade** | Alta, permite múltiplos formatos e finalidades | Baixa, exige esquemas definidos antes do uso |
| **Custo** | Geralmente mais barato devido ao uso de armazenamento bruto | Mais caro, exige processamento e infraestrutura especializados |
| **Velocidade de Acesso** | Pode ser mais lento para consultas complexas | Otimizado para consultas rápidas |
| **Usos Típicos** | Análises exploratórias, aprendizado de máquina, Big Data | Relatórios empresariais e análises operacionais |
| **Ferramentas** | Amazon S3, Azure Data Lake, Hadoop | Amazon Redshift, Google BigQuery, Snowflake |

## Ferramentas e Tecnologias Utilizadas

### Ferramentas Offline (Locais)

Ferramentas offline são instaladas e executadas em servidores ou máquinas locais, sendo gerenciadas pela própria organização. Elas oferecem controle direto sobre os recursos e são mais comuns em empresas que possuem infraestrutura própria ou que lidam com dados altamente sensíveis, onde a regulamentação exige armazenamento local.

**Armazenamento e Bancos de Dados:**

- **PostgreSQL**: um banco de dados relacional avançado, de código aberto, conhecido por sua robustez e conformidade com SQL. Suporta consultas complexas, extensões e alta escalabilidade.
- **MySQL**: banco de dados relacional amplamente utilizado, popular por sua simplicidade e desempenho rápido. Ideal para aplicações web e sistemas menores.
- **SQLite**: banco de dados leve, incorporado diretamente em aplicativos. Não exige um servidor dedicado e é usado frequentemente em dispositivos móveis e aplicativos locais.

- **Apache Cassandra**: banco de dados NoSQL distribuído e escalável, projetado para lidar com grandes volumes de dados em tempo real. Ideal para aplicações que requerem alta disponibilidade.
- **MongoDB**: banco de dados NoSQL que armazena dados em formato JSON, facilitando o gerenciamento de dados não estruturados e escalabilidade horizontal.

**Processamento de Dados:**

- **Apache Hadoop**: *framework* que permite o armazenamento distribuído e processamento de grandes volumes de dados em *clusters*. É usado principalmente em aplicações de *Big Data*.
- **Apache Spark**: plataforma de processamento distribuído altamente eficiente, usada para tarefas como ETL, aprendizado de máquina e análises em tempo real.
- **Apache Airflow**: ferramenta de orquestração de fluxos de trabalho que permite programar, monitorar e gerenciar *pipelines* de dados complexos. Também é usada para tarefas como ETL.

**ETL (Extração, Transformação e Carregamento):**

- **Apache Nifi**: ferramenta poderosa para automação de fluxos de dados, com foco em integração e movimentação entre sistemas de forma visual.

**Linguagens de Programação:**

- **Python**: linguagem versátil e amplamente usada em engenharia de dados. Oferece bibliotecas como pandas, PySpark e SQLAlchemy para manipulação e processamento de dados.
- **SQL**: linguagem padrão para gerenciar e consultar bancos de dados relacionais. Essencial para extrair e transformar dados armazenados em *data warehouses*.

**BI e Visualização:**

- **Power BI Desktop**: ferramenta local da Microsoft para criar relatórios interativos e *dashboards* a partir de diversas fontes de dados.
- **Tableau Desktop**: ferramenta de visualização avançada que permite criar gráficos e *dashboards* altamente personalizáveis com dados locais.

### Ferramentas de Nuvem

Ferramentas na nuvem são serviços fornecidos por provedores como AWS, Google Cloud e Microsoft Azure. Esses serviços são acessados pela internet e permitem armazenar, processar e analisar dados sem a necessidade de infraestrutura física própria. A nuvem é escalável, oferecendo recursos sob demanda e reduzindo custos iniciais de infraestrutura.

**Armazenamento:**

- **Amazon S3**: serviço de armazenamento em nuvem escalável e econômico da AWS, usado para armazenar dados de qualquer tipo e volume.
- **Azure Blob Storage**: solução de armazenamento em nuvem da Microsoft, ideal para grandes volumes de dados não estruturados.
- **Google Cloud Storage**: serviço do Google para armazenar objetos em larga escala, com alta durabilidade e integração com ferramentas de análise.

**Processamento de Dados em Nuvem:**

- **AWS Glue**: serviço gerenciado da AWS para ETL, que automatiza a preparação e movimentação de dados entre fontes.
- **Azure Data Factory**: ferramenta de integração de dados da Microsoft que permite criar pipelines para mover e transformar dados em nuvem.
- **Google Dataflow**: serviço gerenciado do Google para processamento de dados em tempo real ou em lote, usando Apache Beam.

**Bancos de Dados e *Data Warehouses*:**

- **Amazon Redshift**: serviço de *data warehouse* escalável da AWS, projetado para análises rápidas de grandes volumes de dados.
- **Google BigQuery**: solução de *data warehouse* em nuvem que oferece consultas SQL em larga escala com alto desempenho.
- **Snowflake**: plataforma de *data warehouse* independente que combina escalabilidade, desempenho e facilidade de uso em análises de dados na nuvem.

**Orquestração:**

- **AWS Step Functions**: serviço da AWS para orquestrar *workflows* distribuídos e gerenciar pipelines complexos com facilidade.
- **Google Cloud Composer**: ferramenta gerenciada baseada em Apache Airflow para criar e monitorar fluxos de trabalho em nuvem.
- **Prefect**: plataforma moderna e flexível para orquestração de dados, com foco em simplicidade e controle de erros.

**Ferramentas de Visualização na Nuvem:**

- **Looker**: plataforma de visualização do Google que permite criar análises interativas e relatórios a partir de *data warehouses*.
- **Tableau Online**: Versão em nuvem do Tableau, ideal para colaboração em dashboards e relatórios interativos.
- **Microsoft Power BI Service**: Solução em nuvem para compartilhar e consumir relatórios criados no Power BI Desktop.

**Comparação das Ferramentas Offline e Nuvem**

**Ferramentas Offline**

**Vantagens**:

- Total controle sobre os dados e infraestrutura.
- Não depende de conexão com a internet.
- Adequada para organizações com requisitos de conformidade rígidos.

**Desvantagens**:

- Alto custo inicial de implantação.
- Limitações na escalabilidade.
- Maior carga de manutenção e atualizações.

**Ferramentas na Nuvem**

**Vantagens**:

- Escalabilidade e flexibilidade sob demanda.
- Custos iniciais baixos, com modelo de pagamento por uso.

- Atualizações automáticas e manutenção simplificada.

**Desvantagens**:

- Dependência de conexão estável com a internet.
- Custos podem aumentar com uso prolongado ou crescente.
- Percepção de menor controle sobre os dados armazenados em servidores externos.

## O que você aprendeu

- Fundamentos essenciais da engenharia de dados e sua aplicação prática.
- Importância dos **Data Pipelines** na movimentação e transformação dos dados.
- Diferenças entre **Data Lake** e **Data Warehouse** para armazenamento e análise de dados.
- Ferramentas utilizadas por engenheiros de dados, incluindo soluções **offline** e de **nuvem**.
- Base para implementar soluções eficazes no mundo dos dados.