Matemática para Análise de Dados

Asimov Academy

ASIMOV

Conteúdo

01. Introdução à Matemática para Análise de Dados **4**
Problemas no Ensino Tradicional da Matemática . . . 4
Excesso de Técnica e Pouca Compreensão Conceitual . . . 4
Desconexão com a Realidade . . . 4
Principais Áreas Matemáticas para Análise de Dados . . . 5
Cálculo . . . 5
Álgebra Linear . . . 5
Probabilidade e Estatística . . . 5
Conclusão . . . 6

O que são funções? **7**
Definição Simples de Função . . . 7
Representação Gráfica das Funções . . . 7
Construção do Gráfico . . . 7
Exemplos de Funções Clássicas . . . 8
Funções com Múltiplas Variáveis . . . 8
Conclusão . . . 10

03. Introdução ao Conceito de Limites **11**
Exemplificando o Conceito de Limite . . . 11
Compreendendo o Limite . . . 12
Aplicação Prática do Conceito . . . 12
Conclusão . . . 12

04. O que são derivadas? **13**
Exemplo Introdutório: Distância e Tempo . . . 13
Taxa de Variação e Inclinação . . . 13
Derivadas em Funções Não-Lineares . . . 14
Aplicações Práticas . . . 14
Definição Matemática de Derivada . . . 14
Notações Comuns . . . 15
Conclusão . . . 15

05. Aplicando derivadas **17**
Aplicação da Definição Formal da Derivada . . . 17
Regra prática para derivar funções polinomiais . . . 19
Relação entre a função original e sua derivada . . . 19

Importância das derivadas na análise prática de dados 19

06. Derivadas aplicadas à otimização e derivadas parciais 21

Derivada e o Ponto de Mínimo (ou Máximo) 21

Funções com Múltiplas Variáveis e Derivadas Parciais 21

O que são Derivadas Parciais? 21

Por que isso importa para Análise de Dados? 22

07. Introdução à Álgebra Linear e Sistemas de Equações Lineares 23

Definição de Álgebra Linear 23

Sistemas de Equações Lineares 23

Exemplo Prático 23

A Representação Matricial 24

Aplicações na Computação 24

A Intuição por Trás das Matrizes 24

Conclusão 24

08. Matrizes, Vetores e Operações Matriciais 25

Principais Operações com Matrizes 25

Adição e Subtração 25

Multiplicação de Matrizes 25

Tipos Especiais e Outras Operações 26

Escalar 26

Matriz Quadrada e Identidade 26

Transposição de Matrizes 26

Inversão de Matrizes 27

Aplicações Práticas 27

Resumo 27

09. Probabilidade, Estatística e Distribuições: Intuição e Aplicação em Dados 28

O que é Probabilidade Estatística? 28

Distribuições de Probabilidade: Muito Além da Normal 28

Exemplo: Renda 28

Ajustando Modelos aos Dados: O Conceito de Verossimilhança 29

Como funciona na prática? 29

Aplicações Práticas e Conclusão 29

10. Processos Aleatórios e Probabilidade 30

Definindo eventos e probabilidade 30

Generalizando para qualquer situação . . . 30
Conjunto discreto de eventos . . . 30
Propriedades das probabilidades . . . 31
Resumindo . . . 31

11. Lei dos Grandes Números **32**
Exemplo intuitivo: Jogando uma moeda . . . 32
Simulação (e Python!) . . . 32
Exemplo prático: Lei dos Grandes Números em Python . . . 32
Aplicação prática: Tamanho amostral . . . 33

12. Distribuições de Probabilidade **35**
Construindo a ideia . . . 35
Histograma: visualizando a distribuição . . . 35
Distribuições discretas e contínuas . . . 36

13. Independência de eventos e probabilidade condicional **38**
Probabilidade condicional . . . 38
Por que isso importa? . . . 38

14. Esperança matemática de um processo aleatório **39**
Como calcular . . . 39
Moda: outro tipo de centralidade . . . 39
Distribuições contínuas . . . 39
Resumindo . . . 40

15. Variância e desvio padrão **41**

16. A curva de distribuição Gaussiana (Normal) **42**
Fórmula matemática . . . 42
Propriedades de uma distribuição gaussiana (normal) . . . 42

01. Introdução à Matemática para Análise de Dados

A matemática constitui a base essencial para o avanço em praticamente todas as áreas do conhecimento. Sua importância não reside na técnica por si só, mas no fato de ser um poderoso conjunto de ferramentas que permite que pesquisadores e profissionais de diferentes campos alcancem conclusões e desenvolvam novas descobertas. Áreas como Medicina, Física, Psicologia, Química e Ciência de Dados dependem profundamente da matemática.

Contudo, frequentemente o ensino tradicional de matemática nas escolas e universidades pode afastar os estudantes. Isso acontece principalmente devido ao excesso de tecnicalidades e detalhes, que muitas vezes são difíceis de reter ao longo do tempo. Por exemplo, embora a maioria das pessoas compreenda o conceito básico de divisão, poucas conseguem executar cálculos complexos manualmente, pois técnicas muito detalhadas acabam sendo esquecidas com o passar do tempo.

Desta forma, a proposta deste material é destacar principalmente a compreensão conceitual e a intuição por trás dos métodos matemáticos, mais do que os detalhes técnicos específicos. Ao compreender os conceitos fundamentais, o estudante estará preparado para aprofundar-se em técnicas específicas quando necessário.

Problemas no Ensino Tradicional da Matemática

Dois grandes problemas destacam-se na maneira tradicional de ensinar matemática:

Excesso de Técnica e Pouca Compreensão Conceitual

O primeiro problema é o foco excessivo em detalhes técnicos específicos. Na educação formal, frequentemente exige-se que os estudantes dominem todos os passos minuciosos e técnicas específicas para resolver problemas matemáticos, negligenciando muitas vezes a compreensão conceitual e intuitiva da matemática. Este excesso de detalhes técnicos muitas vezes resulta em conhecimento temporário, logo esquecido após sua utilização imediata.

Desconexão com a Realidade

O segundo problema é a falta de conexão clara entre a matemática estudada e aplicações práticas reais. Frequentemente, exercícios e problemas apresentados em ambientes acadêmicos não refletem situações reais do cotidiano ou da vida profissional, dificultando a percepção de relevância e aplicação prática por parte dos estudantes.

O objetivo deste material é justamente oferecer uma abordagem diferente, conectando conceitos matemáticos diretamente com aplicações práticas no campo da análise de dados e da inteligência artificial, focando especialmente em exemplos e intuições úteis para a vida profissional.

Principais Áreas Matemáticas para Análise de Dados

O estudo matemático fundamental para profissionais da área de análise de dados pode ser dividido em três grandes áreas principais e abordaremos essas três ao longo do nosso material. Eles são: cálculo, álgebra linear e probabilidade e estatística.

Cálculo

O cálculo oferece uma base essencial para entender relações entre variáveis e suas taxas de variação. Um dos conceitos fundamentais do cálculo para análise de dados é a derivada, amplamente utilizada em modelos avançados de Machine Learning, especialmente para otimização e ajuste de parâmetros.

Álgebra Linear

A álgebra linear estuda sistemas de equações e relações entre variáveis em múltiplas dimensões. Apesar das diversas definições e abordagens existentes sobre álgebra linear, ela desempenha um papel crucial na construção e otimização de modelos de inteligência artificial, permitindo representar e manipular dados multidimensionais com eficiência.

Probabilidade e Estatística

Probabilidade e estatística são ferramentas essenciais para análise de dados. Mais do que apenas suportar a construção de modelos inteligentes, estas disciplinas fornecem uma estrutura mental poderosa para entender, interpretar e tirar conclusões válidas a partir dos dados. Dominar estes conceitos permite perceber a realidade sob uma perspectiva quantitativa mais clara e objetiva.

A compreensão profunda da probabilidade e da estatística possibilita reconhecer padrões, avaliar riscos e tomar decisões mais informadas e assertivas com base nos dados.

Conclusão

Este capítulo introdutório delineia os conceitos centrais que serão explorados detalhadamente nos próximos módulos, preparando o leitor para desenvolver uma compreensão sólida e prática dos fundamentos matemáticos aplicados à análise de dados.

O que são funções?

Uma função é, essencialmente, uma relação matemática entre duas variáveis. O entendimento desse conceito permite interpretar o mundo ao nosso redor de maneira numérica e quantitativa, o que facilita muito a compreensão de fenômenos naturais e processos em diversas áreas do conhecimento.

Funções estão presentes em praticamente todos os contextos científicos e práticos. Por exemplo, diferentes áreas podem estudar o mesmo objeto de formas variadas, utilizando o conceito de função. Um químico poderia investigar como o sabor de uma bebida é influenciado por componentes específicos adicionados a ela; um psicólogo poderia analisar como o consumo dessa bebida afeta níveis de ansiedade; um médico poderia investigar relações entre o consumo da bebida e incidência de doenças específicas; e um físico poderia estudar como a temperatura dessa bebida é influenciada pelos materiais do recipiente.

Cada um desses estudos poderia ser representado graficamente, utilizando um eixo (X) para representar a variável independente e outro eixo (Y) para a variável dependente estudada. A relação estabelecida entre essas variáveis é o que chamamos de função.

Definição Simples de Função

De maneira simples, pode-se dizer que uma função existe sempre que o valor de uma variável Y depende exclusivamente do valor atribuído a outra variável X. Formalmente, diz-se que Y é função de X e utiliza-se a notação:

Isso significa que o valor de Y será determinado diretamente pelo valor atribuído a X, embora na realidade Y possa depender de múltiplas outras variáveis.

Representação Gráfica das Funções

Uma maneira prática de visualizar funções é através da representação gráfica em um sistema de coordenadas conhecido como plano cartesiano, formado por dois eixos perpendiculares, X e Y. O eixo horizontal (X) representa a variável independente, enquanto o eixo vertical (Y) representa a variável dependente.

Construção do Gráfico

Para construir um gráfico simples, como por exemplo, $y = 2x + 3$, atribuem-se diferentes valores para X e calculam-se os correspondentes valores de Y:

X	Y
0	3
1	5
2	7
3	9

Marcando estes pontos no plano cartesiano, pode-se unir os pontos e formar uma reta, ilustrando graficamente a função.

Exemplos de Funções Clássicas

Algumas funções têm características especiais e aparecem com frequência em diversos contextos científicos e práticos:

- **Função linear ($y = x$)**: o crescimento é diretamente proporcional.
- **Função quadrática ($y = x^2$)**: apresenta crescimento acelerado, formando uma parábola.
- **Função cúbica ($y = x^3$)**: permite valores negativos e positivos, com crescimento acelerado em ambas as direções.
- **Função racional ($y = 1 / x$)**: comportamento característico com aproximação infinita dos eixos sem tocá-los.
- **Função raiz quadrada ($y = \sqrt{x}$)**: crescimento rápido inicialmente, depois reduzido.
- **Função logarítmica ($y = \log(x)$)**: comportamento característico, iniciando negativa para valores pequenos de X e cruzando o eixo X quando X é igual a 1.

Esses gráficos auxiliam na compreensão da natureza das funções e facilitam a identificação de padrões em conjuntos de dados reais.

Funções com Múltiplas Variáveis

Na prática, a maioria dos fenômenos naturais depende de várias variáveis simultaneamente. Neste caso, a função pode ser representada por múltiplas dependências:

```
Y = f(X1, X2, X3, ..., Xn)
```

Exemplos de representações poderiam incluir:

- **Exemplo 1**: `Y = X1 + X2 + X3`

- **Exemplo 2**: `Y = 3X1 + 2X2`
- **Exemplo 3**: `Y = sum_{i=1}^n X_i`

Essas representações evidenciam a complexidade das funções reais e sua aplicação prática em problemas multidimensionais, comuns no cotidiano da análise de dados.

Segue um exemplo visual para uma melhor compreensão:

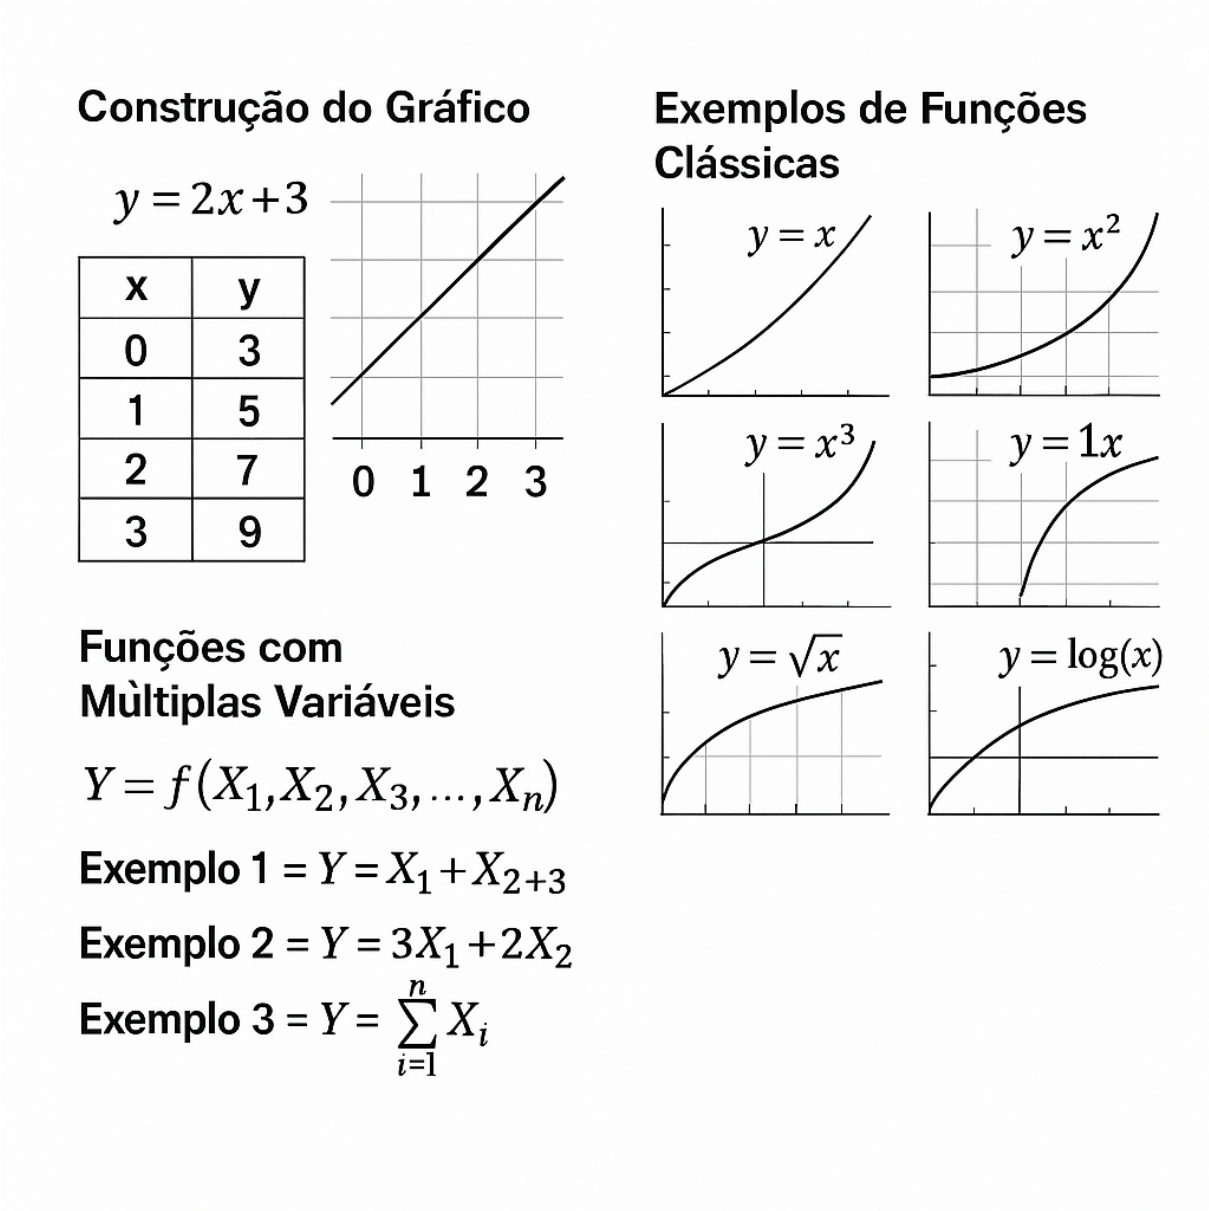

Figure 1: Exemplo visual gráfico

Conclusão

Com este capítulo, espera-se que o leitor tenha uma visão clara e intuitiva das funções, compreendendo seu papel fundamental na análise quantitativa de dados e fenômenos naturais.

03. Introdução ao Conceito de Limites

O conceito de limite é uma ferramenta matemática que auxilia na compreensão do comportamento das funções em pontos específicos, especialmente quando a função apresenta algum tipo de indefinição ou dificuldade de avaliação direta.

Em muitas situações, funções podem apresentar problemas como divisões por zero, tornando sua avaliação direta impossível em certos pontos. Nesses casos, o conceito de limite é utilizado para analisar o comportamento da função à medida que ela se aproxima desses pontos problemáticos.

Exemplificando o Conceito de Limite

Considere a função matemática:

$$f(x) = \frac{x-1}{x-1}$$

À primeira vista, para a grande maioria dos valores de , essa função parece simples e constante, resultando sempre em 1. Contudo, existe um ponto específico que gera uma indefinição matemática: quando .

Neste ponto exato:

$$f(1) = \frac{1-1}{1-1} = \frac{0}{0}$$

Como divisões por zero não são permitidas matematicamente, diz-se que a função não é definida exatamente nesse ponto.

Compreendendo o Limite

O limite busca avaliar o comportamento da função à medida que ela se aproxima do ponto problemático, sem efetivamente atingi-lo. Assim, podemos afirmar:

$$\lim_{x \to 1} \frac{x-1}{x-1} = 1$$

Essa expressão significa que quanto mais se aproximar de 1 (por valores próximos como 1,000001 ou 0,999999), mais a função se aproximará do valor 1.

Aplicação Prática do Conceito

Na prática, para determinar o limite de uma função, geralmente basta substituir o valor limite diretamente na função. Entretanto, como exemplificado, existem situações específicas em que a substituição direta gera uma indefinição, requerendo o uso explícito do conceito de limite.

É importante ressaltar que o estudo detalhado e extenso de técnicas específicas para calcular limites em diversos tipos de funções é comum em cursos formais de matemática, embora muitas dessas técnicas não tenham aplicações práticas imediatas. O essencial é compreender o conceito de limite em si, pois ele servirá como fundamento crucial para entender tópicos avançados, como derivadas.

Conclusão

Este capítulo apresentou o conceito de limites de maneira clara e simplificada, preparando o leitor para avançar nos próximos tópicos fundamentais da matemática aplicada à análise de dados e Machine Learning.

04. O que são derivadas?

Derivadas são um dos conceitos mais fundamentais do cálculo e possuem amplas aplicações na ciência de dados, na física, na engenharia e em diversas outras áreas. De forma geral, a derivada representa a **taxa de variação** de uma variável em relação a outra. Em outras palavras, descreve como uma quantidade muda à medida que outra muda.

Exemplo Introdutório: Distância e Tempo

Considere uma situação em que se registra a distância percorrida por um veículo ao longo do tempo:

Tempo (horas)	Distância (km)
1,0	60
1,5	90
2,0	120

A relação entre distância e tempo pode ser representada por uma função simples: D = T, onde a distância D é função do tempo T. Essa função indica que, a cada hora, o veículo percorre 60 km — ou seja, sua velocidade é constante.

Neste caso, a **derivada** da função distância em relação ao tempo representa a **velocidade instantânea**, que é constante e igual a 60 km/h.

Taxa de Variação e Inclinação

Para analisar variações ao longo do tempo, pode-se observar a inclinação da reta no gráfico que representa a função. Em uma reta, essa inclinação é constante e pode ser calculada pela razão entre o cateto oposto e o cateto adjacente em um triângulo formado entre dois pontos:

$$\text{Inclinação} = \frac{\Delta Y}{\Delta X}$$

Quando a inclinação muda de ponto a ponto, ou seja, em gráficos não-lineares, a derivada fornece uma forma de determinar essa taxa de variação para cada ponto da curva. Essa inclinação, em um ponto específico, é conhecida como a **reta tangente** à curva nesse ponto.

Derivadas em Funções Não-Lineares

Se a distância ao longo do tempo não fosse constante — por exemplo, devido a engarrafamentos ou variações de velocidade — o gráfico da função deixaria de ser uma reta. A função poderia apresentar trechos curvos, representando acelerações ou paradas. Em cada ponto da curva, a derivada indicaria a velocidade instantânea naquele momento.

Assim, enquanto uma função descreve o comportamento de uma variável ao longo do tempo, a derivada descreve **como** esse comportamento muda — ou seja, a **velocidade de mudança** da variável dependente em relação à independente.

Aplicações Práticas

Derivadas são aplicáveis em múltiplos contextos, como:

- Avaliar a velocidade de variação da temperatura de um líquido ao longo do tempo;
- Medir como a taxa de crescimento populacional muda com o tempo;
- Calcular a inclinação de um gráfico de lucro ao longo das semanas;
- Analisar o comportamento de variáveis em modelos preditivos em ciência de dados.

Em todos esses casos, a derivada fornece informações sobre o comportamento **dinâmico** de sistemas.

Definição Matemática de Derivada

A derivada de uma função em um ponto específico pode ser compreendida a partir do conceito de **limite**. Considere dois pontos em uma função: x0 (o ponto de interesse) e x (um ponto próximo a). A

inclinação da reta entre esses pontos é dada por:

$$\frac{f(x) - f(x_0)}{x - x_0}$$

Para obter a inclinação exata no ponto x0, calcula-se o **limite** dessa expressão quando x tende a x0:

$$\lim_{x \to x_0} \frac{f(x) - f(x_0)}{x - x_0}$$

Essa expressão define formalmente a **derivada da função f em relação a x no ponto x_0**.

Notações Comuns

Existem diversas notações para representar derivadas, como:

- f'(x)
- g(x)
- df(x)/dx

Todas elas representam a mesma ideia: a taxa de variação da função em relação à sua variável independente. A notação df(x)/dx é particularmente útil por explicitar que a derivada é em relação a x.

Conclusão

A derivada é uma ferramenta poderosa que permite entender, interpretar e modelar o comportamento dinâmico de variáveis em múltiplas disciplinas. Mais do que decorar regras e técnicas de derivação, é fundamental compreender a **intuição** por trás do conceito: a derivada revela **como uma variável muda à medida que outra muda**, ponto a ponto.

Nos próximos capítulos, serão apresentados exemplos práticos de derivação de funções e sua aplicação em problemas analíticos reais.

05. Aplicando derivadas

No capítulo anterior, definimos o conceito de derivada como a taxa de variação instantânea de uma variável em relação à outra. Agora, aplicaremos esse conceito em funções analíticas simples para compreender melhor seu significado e como ele é útil em problemas reais.

Aplicação da Definição Formal da Derivada

Relembrando a definição formal de derivada, temos:

$$f'(x_0) = \lim_{x \to x_0} \frac{f(x) - f(x_0)}{x - x_0}$$

Vamos utilizar essa definição em exemplos práticos para fixar o entendimento.

Considere a função: $y = x^2$

Queremos descobrir qual é a derivada dessa função no ponto x =3. Isso significa determinar a taxa de variação instantânea nesse ponto específico.

Aplicando a definição formal, temos:

$$f'(3) = \lim_{x \to 3} \frac{x^2 - 3^2}{x - 3} = \lim_{x \to 3} \frac{x^2 - 9}{x - 3}$$

Observe que substituir diretamente $x = 3$ gera uma indeterminação (divisão por zero). Podemos contornar essa questão usando uma decomposição algébrica: $x^2 - 9 = (x + 3)(x - 3)$

Dessa forma:

$$f'(3) = \lim_{x \to 3} \frac{(x-3)(x+3)}{x-3}$$

Simplificando a expressão, chegamos a:

$$f'(3) = \lim_{x \to 3} (x+3) = 3 + 3 = 6$$

O valor encontrado, 6, indica que, nesse ponto específico da curva, uma variação unitária no valor de x provoca uma variação de 6 unidades no valor de y, caso a curva passasse a ser linear a partir desse ponto.

Podemos generalizar essa abordagem para determinar a derivada em qualquer ponto x_0:

$$f'(x_0) = \lim_{x \to x_0} \frac{x^2 - x_0^2}{x - x_0}$$

Usando novamente a decomposição algébrica, temos:

$$f'(x_0) = \lim_{x \to x_0} \frac{(x+x_0)(x-x_0)}{x-x_0} = \lim_{x \to x_0} (x+x_0) = 2x_0$$

Portanto, a derivada geral da função $y=x^2$ é dada por:

$$\frac{dy}{dx} = 2x$$

Essa função derivada descreve como a inclinação da curva varia ao longo dos valores de x.

Regra prática para derivar funções polinomiais

Existe uma regra prática que simplifica o cálculo da derivada de funções polinomiais do tipo x^n:

$$\frac{d}{dx}(x^n) = nx^{n-1}$$

Essa regra afirma que devemos multiplicar o termo x pelo expoente n e, em seguida, subtrair 1 do expoente original.

Por exemplo, na função $y = x^2$:

- Multiplicamos o expoente (2) por x, resultando em $2x$;
- Subtraímos 1 do expoente, obtendo $2x^{2-1} = 2x$.

Aplicando a regra prática para a função simples $y = x$ (que é o mesmo que x^1):

$$\frac{dy}{dx} = 1 \cdot x^{1-1} = 1 \cdot x^0 = 1$$

Nesse caso, a derivada é constante (igual a 1), indicando que a inclinação da reta permanece constante, independente do ponto em que estamos analisando.

Relação entre a função original e sua derivada

A derivada de uma função nos informa como essa função varia para cada ponto específico. Se observarmos a função original $y = x^2$ e sua derivada $y' = x$, veremos que à medida que x aumenta, a inclinação (representada pela derivada) também aumenta linearmente. Isso implica que a função original se torna cada vez mais "íngreme" à medida que nos afastamos da origem.

Graficamente, para cada valor específico de x, a derivada corresponde exatamente à inclinação da reta tangente à curva naquele ponto.

Importância das derivadas na análise prática de dados

As derivadas são especialmente úteis em situações como:

- Encontrar pontos de máximo e mínimo em gráficos de lucro ou custo;

- Avaliar velocidades instantâneas em sistemas físicos;
- Compreender a variação instantânea de variáveis em modelos estatísticos ou de machine learning.

Nos próximos capítulos, exploraremos mais profundamente como utilizar derivadas para resolver esses tipos de problemas práticos.

06. Derivadas aplicadas à otimização e derivadas parciais

Em problemas de Machine Learning, uma das aplicações mais práticas das derivadas é na **otimização de funções**. Quando treinamos modelos, normalmente estamos ajustando parâmetros para minimizar (ou maximizar) uma função, chamada de **função custo**. Essa função avalia o desempenho do modelo, indicando o quão bem ele está fazendo suas previsões.

Por exemplo, ao tentar prever a qualidade de um café a partir de suas características, podemos criar uma função que penaliza erros de previsão. Nosso objetivo será ajustar os parâmetros dessa função para que ela atinja o menor valor possível — ou seja, minimizar o custo.

Derivada e o Ponto de Mínimo (ou Máximo)

Em termos matemáticos, **o mínimo ou máximo de uma função ocorre quando sua derivada é igual a zero**:

$$\frac{df}{dx} = 0$$

- **Mínimo**: antes do ponto, a derivada é negativa (função decrescente); depois do ponto, é positiva (função crescente).
- **Máximo**: antes do ponto, a derivada é positiva; depois, negativa.

Essa técnica é essencial para entender como encontrar o melhor ajuste de um modelo, seja minimizando erros ou maximizando acertos.

Funções com Múltiplas Variáveis e Derivadas Parciais

Até agora, trabalhamos com funções de uma única variável x. Na prática, porém, a maioria dos problemas envolve funções com múltiplas variáveis, como $x1, x2, x3$ etc. Por exemplo, o desempenho de um modelo pode depender de vários parâmetros ao mesmo tempo.

Nesse cenário, utilizamos o conceito de **derivadas parciais** para entender como cada variável afeta a função individualmente.

O que são Derivadas Parciais?

As **derivadas parciais** medem como a função varia quando alteramos apenas uma das variáveis, mantendo as demais fixas. A notação comum é:

$$\frac{\partial y}{\partial x_1} \quad \text{e} \quad \frac{\partial y}{\partial x_2}$$

Exemplo Prático Considere a função:

Considere a função:

$$y = 2x_1 + 3x_2^2$$

- **Derivada de y em relação a x_1:** tratamos x_2 como constante. $\frac{\partial y}{\partial x_1} = 2$.
- **Derivada de y em relação a x_2:** tratamos x_1 como constante. $\frac{\partial y}{\partial x_2} = 6x_2$.

Essas derivadas mostram como x_1 e x_2 afetam y individualmente.

Por que isso importa para Análise de Dados?

Em Machine Learning, quase sempre lidamos com múltiplas variáveis. As derivadas parciais permitem calcular gradientes que indicam a direção em que devemos ajustar cada parâmetro para melhorar o modelo. Esse é o princípio básico por trás de algoritmos como **gradiente descendente**.

07. Introdução à Álgebra Linear e Sistemas de Equações Lineares

A álgebra linear é uma das áreas fundamentais da matemática, especialmente relevante em **Data Science** e **Machine Learning**. Ela se concentra no estudo de **sistemas de equações lineares** e como essas equações podem ser representadas e resolvidas de maneira eficiente.

Definição de Álgebra Linear

A definição clássica de álgebra linear foca no estudo de **planos e vetores**, mas uma definição mais intuitiva pode ser o estudo dos **sistemas de equações lineares**, onde temos múltiplas equações que envolvem várias variáveis. Ao resolver esses sistemas, podemos determinar os valores dessas variáveis que satisfazem todas as equações simultaneamente.

Sistemas de Equações Lineares

Um **sistema de equações lineares** é um conjunto de equações que envolvem as mesmas variáveis. Por exemplo:

$$y + 2x = 2$$
$$3y - x = 4$$

Essas equações podem ser representadas graficamente em um plano, onde as soluções correspondem aos pontos de interseção das linhas no gráfico. Quando as equações formam linhas retas, o sistema é considerado linear.

Exemplo Prático

Considerando o exemplo de um problema no **Papiro de Hames**, de 1650 a.C., onde se procurava dividir 100 sacos de cevada entre 5 homens com uma progressão aritmética, podemos escrever um sistema de equações para resolver o problema. O objetivo é encontrar as variáveis x e y, onde x representa o valor inicial e y o fator de crescimento aritmético.

A Representação Matricial

Quando lidamos com um número grande de equações e variáveis, a **representação matricial** se torna útil. Uma **matriz** é simplesmente uma tabela organizada de números que representa os coeficientes das variáveis em um sistema de equações. Por exemplo, o sistema de equações pode ser representado pela seguinte matriz:

$$\begin{pmatrix} 1 & 1 & 4 \\ 1 & 4 & 1 \end{pmatrix}$$

Essa tabela ajuda a resolver sistemas de equações de maneira mais eficiente, especialmente em modelos de Machine Learning, que frequentemente lidam com grandes quantidades de variáveis.

Aplicações na Computação

A álgebra linear tem uma vasta aplicação em **computação**, especialmente em algoritmos de **machine learning**. Por exemplo, um algoritmo de **classificação de imagens** representa cada imagem como uma matriz de **pixels**. Operações matriciais são realizadas para processar e classificar essas imagens, sendo um exemplo clássico de como a álgebra linear é usada na prática para representar e resolver problemas computacionais.

A Intuição por Trás das Matrizes

Embora o conceito de álgebra linear e matrizes possa parecer abstrato no início, ele oferece uma ferramenta poderosa para lidar com problemas de grande escala. Quando temos muitos parâmetros ou equações, a matriz oferece uma maneira sistemática e eficiente de organizar e calcular as soluções.

Conclusão

A álgebra linear nos fornece as ferramentas essenciais para entender e trabalhar com sistemas de equações lineares, essenciais para a construção de modelos matemáticos complexos. Embora você possa usar técnicas de Machine Learning sem dominar completamente a álgebra linear, entender os conceitos por trás de **matrizes** e **sistemas de equações** facilitará a compreensão e o desenvolvimento de modelos mais avançados.

08. Matrizes, Vetores e Operações Matriciais

Matriz é o elemento central da álgebra linear. Matematicamente, **matriz** é uma tabela de números organizada em linhas e colunas. Por exemplo, uma matriz 3x3 possui 3 linhas e 3 colunas. Quando uma dessas dimensões é igual a 1 (apenas uma linha ou uma coluna), chamamos de **vetor**. Na física, o termo vetor pode indicar sentido e direção, mas na álgebra linear, é uma matriz simplificada. Na prática, o conceito de matriz aparece em diversas áreas: em tabelas do Excel, controles de custo, manipulação de dados em Data Science, ou mesmo em representações de imagens em computação. Sempre que você lida com dados tabulares, está usando, mesmo que sem perceber, a ideia de matrizes e vetores.

Principais Operações com Matrizes

Assim como os números, matrizes podem ser somadas, subtraídas e multiplicadas, mas seguindo regras próprias:

Adição e Subtração

Só podem ser somadas (ou subtraídas) matrizes de mesmo tamanho. Exemplo:

Se

$$A = \begin{bmatrix} 2 & 4 \\ 3 & 5 \end{bmatrix}$$

$$B = \begin{bmatrix} 1 & 6 \\ 9 & 7 \end{bmatrix}$$

então

$$A + B = \begin{bmatrix} 2+1 & 4+6 \\ 3+9 & 5+7 \end{bmatrix} = \begin{bmatrix} 3 & 10 \\ 12 & 12 \end{bmatrix}$$

Multiplicação de Matrizes

A multiplicação de matrizes é diferente da multiplicação elemento a elemento. A regra principal é: *Para multiplicar duas matrizes, o número de colunas da primeira deve ser igual ao número de linhas da segunda.*

Exemplo:
Se A é 2x3 e B é 3x2, o resultado será uma matriz 2x2.

O cálculo do elemento é feito multiplicando as linhas da primeira pelas colunas da segunda e somando os resultados.

Importante: A ordem importa! Em geral, A × B ≠ B × A.

No Python, a multiplicação ponto a ponto é chamada de **dot product**, e a multiplicação matricial é essencial para modelos como a regressão linear, onde operações desse tipo aparecem o tempo todo.

Tipos Especiais e Outras Operações

Escalar

Um escalar é apenas um número, podendo ser visto como uma matriz 1x1.

Matriz Quadrada e Identidade

- **Matriz quadrada:** possui o mesmo número de linhas e colunas.
- **Matriz identidade (I):** é a "versão 1" das matrizes; tem 1s na diagonal principal e 0s nos demais elementos.
- Ao multiplicar qualquer matriz A pela identidade I, o resultado é a própria matriz A.

Transposição de Matrizes

Transpor uma matriz significa trocar linhas por colunas.

Exemplo:

$$A = \begin{bmatrix} 2 & 4 \\ 6 & 9 \end{bmatrix}$$

$$A^T = \begin{bmatrix} 2 & 6 \\ 4 & 9 \end{bmatrix}$$

Esse conceito é utilizado em manipulação de dados (por exemplo, no Pandas, com `df.T`) e aparece em operações de modelos de Machine Learning.

Inversão de Matrizes

A **matriz inversa** de A é aquela que, multiplicada por A, resulta na identidade:

$A \times A^{-1} = I$

Nem toda matriz tem inversa, e calcular a inversa pode ser trabalhoso para matrizes grandes. Mas o conceito é fundamental, por exemplo, na resolução de sistemas lineares e em alguns algoritmos de regressão linear.

Aplicações Práticas

- **Imagens**: representadas por matrizes de pixels.
- **Modelos de Machine Learning**: processam dados tabulares ou imagens por meio de operações matriciais.
- **Ciência de Dados**: tabelas e DataFrames são representações matriciais que facilitam operações em lote.

Resumo

- Matrizes são tabelas de números; vetores são matrizes com uma única linha ou coluna.
- Operações básicas: adição, subtração, multiplicação, transposição e inversão.
- Matriz identidade funciona como o número 1 nas matrizes.
- Conceitos de álgebra linear aparecem diariamente na manipulação de dados e são essenciais para algoritmos de Machine Learning.

09. Probabilidade, Estatística e Distribuições: Intuição e Aplicação em Dados

Probabilidade e estatística são áreas fundamentais não só em Machine Learning, mas em qualquer análise de dados. Elas fornecem as ferramentas para descrever e compreender a **aleatoriedade** do mundo — algo presente em praticamente todas as áreas científicas. Entender estatística é essencial não apenas para construir modelos inteligentes, mas também para analisar dados, interpretar resultados e tomar decisões baseadas em evidências, seja em ciência, negócios ou na vida cotidiana. Ter domínio de probabilidade e estatística é o que separa o bom do mau cientista de dados.

O que é Probabilidade Estatística?

Probabilidade estatística é o conjunto de ferramentas usadas para descrever e compreender fenômenos aleatórios, permitindo tirar conclusões corretas a partir de dados.
Todo estudo científico — de medicina à física, de economia à biologia — depende desses conceitos para validar resultados e embasar decisões.

Distribuições de Probabilidade: Muito Além da Normal

A distribuição **normal** (curva em formato de sino) é a mais conhecida e aparece em muitos fenômenos naturais. Porém, nem todos os dados do mundo real seguem esse padrão.

Exemplo: Renda

A distribuição da renda de uma população costuma ser bastante assimétrica: muita gente recebe pouco e poucas pessoas ganham muito. Esse padrão, chamado de "cauda longa", **não** pode ser bem representado pela distribuição normal.

Outros exemplos de distribuições:

- **LogNormal:** Usada para representar variáveis positivas assimétricas, como renda.
- **Poisson:** Modela o número de eventos em determinado intervalo (ex: chamadas de telefone por minuto).
- **Exponencial:** Representa fenômenos como a meia-vida de medicamentos no sangue, ou seja, quanto tempo leva para a concentração de um fármaco cair pela metade.

Cada fenômeno do mundo real pode ser melhor representado por um tipo de distribuição, e existe uma família de funções matemáticas para cada situação.

Ajustando Modelos aos Dados: O Conceito de Verossimilhança

Quando buscamos representar um conjunto de dados por uma função matemática (por exemplo, a distribuição de alturas das pessoas, ou o tempo de atendimento de uma fila), precisamos **ajustar os parâmetros dessa função** para que ela descreva bem o fenômeno observado.

O conceito de **verossimilhança** (ou likelihood) mede o quanto os dados coletados se parecem com uma curva/função escolhida e seus parâmetros.

Como funciona na prática?

1. **Escolha um modelo:** Por exemplo, a distribuição normal para alturas.
2. **Ajuste os parâmetros:** Encontre a média (μ) e o desvio padrão (σ) que melhor "encaixam" nos dados.
3. **Calcule a verossimilhança:** Para cada dado observado, calcule a probabilidade de ele ter ocorrido dado o modelo e os parâmetros escolhidos. Multiplique essas probabilidades.
4. **Maximize a verossimilhança:** O melhor ajuste dos parâmetros é aquele que **maximiza** a verossimilhança.

É assim que, matematicamente, são obtidas as fórmulas da média e do desvio padrão que aprendemos na escola.

Aplicações Práticas e Conclusão

- Em ciência de dados, escolher e ajustar distribuições é essencial para fazer inferências, prever fenômenos e construir modelos de Machine Learning.
- Nem todo conjunto de dados segue a distribuição normal; saber escolher o modelo certo faz diferença nos resultados.
- O conceito de verossimilhança é a base para métodos estatísticos modernos, como máxima verossimilhança, testes de hipóteses e ajuste de modelos preditivos.

Resumo prático:

> Probabilidade e estatística são o coração da análise de dados. Dominar seus conceitos permite descrever, prever e agir melhor diante da incerteza.

10. Processos Aleatórios e Probabilidade

Um **processo aleatório** é qualquer situação na qual não sabemos de antemão qual será o resultado, mas podemos descrever as possíveis saídas e calcular a chance de cada uma delas ocorrer.
Exemplo clássico: jogar um dado. Ao lançar o dado, não conseguimos prever o número que irá sair, mas sabemos que é um dos seis lados possíveis.

Definindo eventos e probabilidade

Cada possível resultado de um processo aleatório é chamado de **evento**.
No caso do dado, os eventos possíveis são tirar 1, 2, 3, 4, 5 ou 6.

A **probabilidade** de um evento é a proporção de vezes que ele ocorre se repetirmos o processo aleatório muitas vezes.
Exemplo: Se o dado não for viciado, a chance de sair qualquer número é igual para todos os lados, ou seja:

$$P(\text{tirar } 1) = P(\text{tirar } 2) = \cdots = P(\text{tirar } 6) = \frac{1}{6} \approx 16{,}6\%$$

Generalizando para qualquer situação

O conceito de processo aleatório e evento se aplica a qualquer situação incerta do dia a dia:

- Probabilidade de a primeira pessoa na rua ser canhota.
- Probabilidade de sair cara ou coroa em um lançamento de moeda.
- Probabilidade de chover amanhã.
- Probabilidade de um time ganhar uma partida.

Processo aleatório: a situação incerta (lançar dado, lançar moeda, sorteio, etc).
Evento: um resultado específico desse processo (tirar 4, sair coroa, etc).

Conjunto discreto de eventos

No exemplo do dado, os possíveis resultados (eventos) são **discretos**, ou seja, um conjunto finito de opções (1 a 6).
Quando trabalhamos com processos aleatórios contínuos (exemplo: altura de pessoas), o conjunto de resultados pode ser infinito, mas neste capítulo o foco são processos com número finito de resultados.

Propriedades das probabilidades

- A probabilidade de qualquer evento sempre estará entre 0 e 1 (ou entre 0% e 100%).
- **A soma das probabilidades de todos os eventos possíveis de um processo aleatório deve ser igual a 1**.
  Exemplo: $P(1) + P(2) + P(3) + P(4) + P(5) + P(6) = 1$

Se a soma for diferente de 1, existe algum erro no modelo probabilístico.

Resumindo

- **Processo aleatório**: situação com resultado incerto, mas descrito por possíveis eventos.
- **Evento**: cada resultado possível.
- **Probabilidade**: frequência esperada de cada evento ao repetir o processo aleatório muitas vezes.
- **Propriedades**: valores entre 0 e 1; soma total igual a 1.

11. Lei dos Grandes Números

A **Lei dos Grandes Números** é um conceito fundamental em probabilidade estatística. Ela afirma que, à medida que repetimos um experimento aleatório muitas e muitas vezes, a frequência relativa de um evento tende a se aproximar do seu valor real de probabilidade.

Exemplo intuitivo: Jogando uma moeda

Imagine jogar uma moeda honesta (não viciada) várias vezes.

- Se jogar uma vez e der "cara", você pode achar que a moeda só dá cara (100% de probabilidade).
- Se jogar cinco vezes e der cinco caras, pode desconfiar que há algo errado.
  Mas será que uma amostra tão pequena é suficiente para tirar conclusões?

A resposta é não!
Só quando aumentamos muito o número de repetições, a proporção de caras tende a se estabilizar em 50%, que é o valor real de probabilidade para uma moeda justa.

Simulação (e Python!)

Para ilustrar, você pode simular esse processo com um código Python (usando NumPy e Matplotlib) e observar que:

- Com poucas jogadas, a proporção de caras varia muito.
- Com milhares de jogadas, a proporção converge para 50%.

Esse é o poder da Lei dos Grandes Números:

> Quanto maior o tamanho da amostra, mais confiável é a nossa estimativa da probabilidade real.

Exemplo prático: Lei dos Grandes Números em Python

Abaixo, um código simples que simula lançamentos de uma moeda honesta. Observe como a proporção de "caras" se aproxima de 0,5 conforme o número de lançamentos aumenta.

```
import numpy as np
import matplotlib.pyplot as plt

# Parâmetros
num_lancamentos = 1000  # Você pode testar com valores maiores
```

```
# Simulação: 0 = coroa, 1 = cara
resultados = np.random.choice([0, 1], size=num_lancamentos)

# Calculando proporção acumulada de caras a cada lançamento
proporcao_caras = np.cumsum(resultados) / (np.arange(1, num_lancamentos + 1))

# Gráfico
plt.figure(figsize=(10,5))
plt.plot(proporcao_caras, label='Proporção de caras')
plt.axhline(0.5, color='red', linestyle='--', label='Probabilidade real (0.5)')
plt.xlabel('Número de lançamentos')
plt.ylabel('Proporção acumulada de caras')
plt.title('Lei dos Grandes Números: Simulação com moeda honesta')
plt.legend()
plt.show()
```

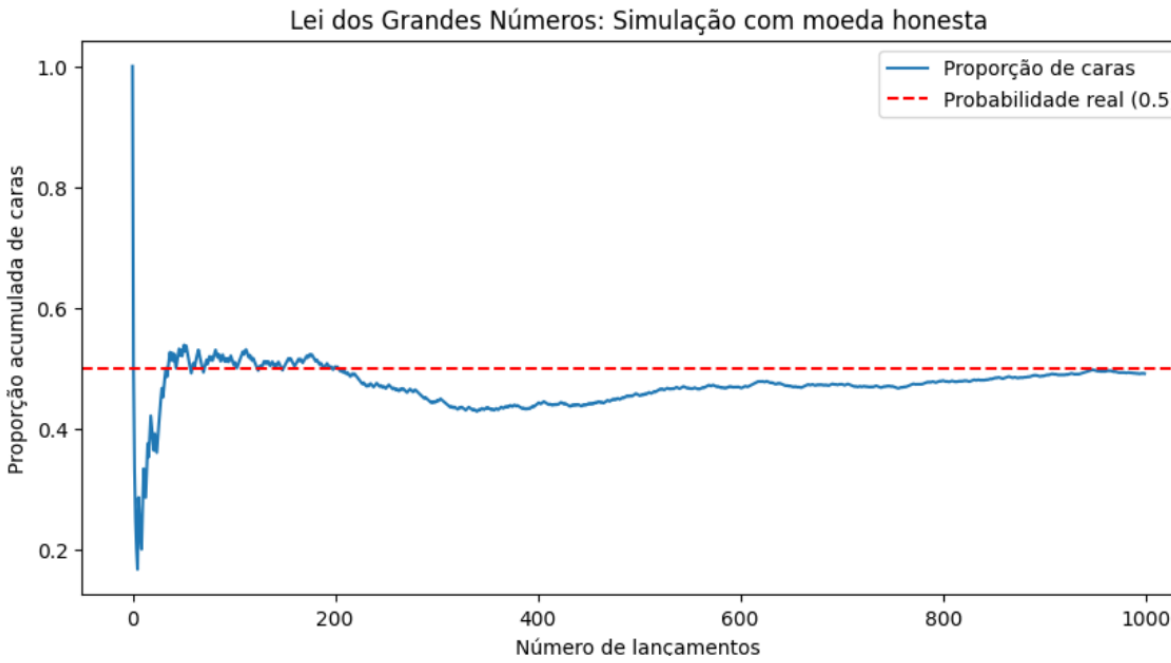

Gráfico plotado

Aplicação prática: Tamanho amostral

Na vida real, é comum tirar conclusões precipitadas com base em poucas observações (amostra pequena).
A Lei dos Grandes Números nos ensina que **não podemos confiar em conclusões baseadas em poucas experiências** — seja para dados científicos, decisões no mercado financeiro, ou até em debates cotidianos.

Quanto maior o número de repetições (amostras), mais próximo estaremos da "verdade estatística".
Resumo

- **A Lei dos Grandes Números** garante que as estimativas de probabilidade ficam mais precisas com grandes amostras.
- **Evite conclusões precipitadas:** Não confie em resultados baseados em poucos dados!
- O tamanho da amostra é fundamental para validar conclusões na ciência de dados, pesquisas, e no dia a dia.

12. Distribuições de Probabilidade

Ao estudar processos aleatórios, vimos que cada resultado possível de um experimento tem uma chance (probabilidade) de acontecer.
A **distribuição de probabilidade** é a forma organizada de representar todas essas probabilidades, seja em uma tabela, função ou gráfico.

Construindo a ideia

Imagine um processo aleatório qualquer — como perguntar ao acaso para várias pessoas o estado onde nasceram.

- Cada resposta possível (evento) tem uma probabilidade associada.
- Podemos construir uma **tabela** que mostra, para cada evento, sua probabilidade:

Evento (estado)	Probabilidade
Rio Grande do Sul	0,90
São Paulo	0,03
Rio de Janeiro	0,02
Santa Catarina	0,01
Outros	0,04

- A soma de todas as probabilidades deve ser igual a 1 (ou 100%).

Histograma: visualizando a distribuição

O **histograma** é um gráfico de barras que mostra como as probabilidades estão distribuídas entre os eventos.

- Cada barra representa um evento.
- A altura da barra mostra a probabilidade desse evento.

Essa representação é fundamental para entender padrões e tomar decisões baseadas em dados.

Aqui está um exemplo de código em Python que você pode usar para visualizar esses dados como um histograma:

```
import matplotlib.pyplot as plt

# Dados do exemplo
eventos = ['RS', 'SP', 'RJ', 'SC', 'Outros']
probabilidades = [0.90, 0.03, 0.02, 0.01, 0.04]

# Criando o histograma de barras
plt.figure(figsize=(8,5))
plt.bar(eventos, probabilidades, color='skyblue')
plt.title('Distribuição de Probabilidade por Estado')
plt.xlabel('Estado de Nascimento')
plt.ylabel('Probabilidade')
plt.ylim(0, 1)
plt.grid(axis='y', linestyle='--', alpha=0.6)
plt.show()
```

Depois de rodar o código, você verá um histograma como este sendo exibido em sua tela:

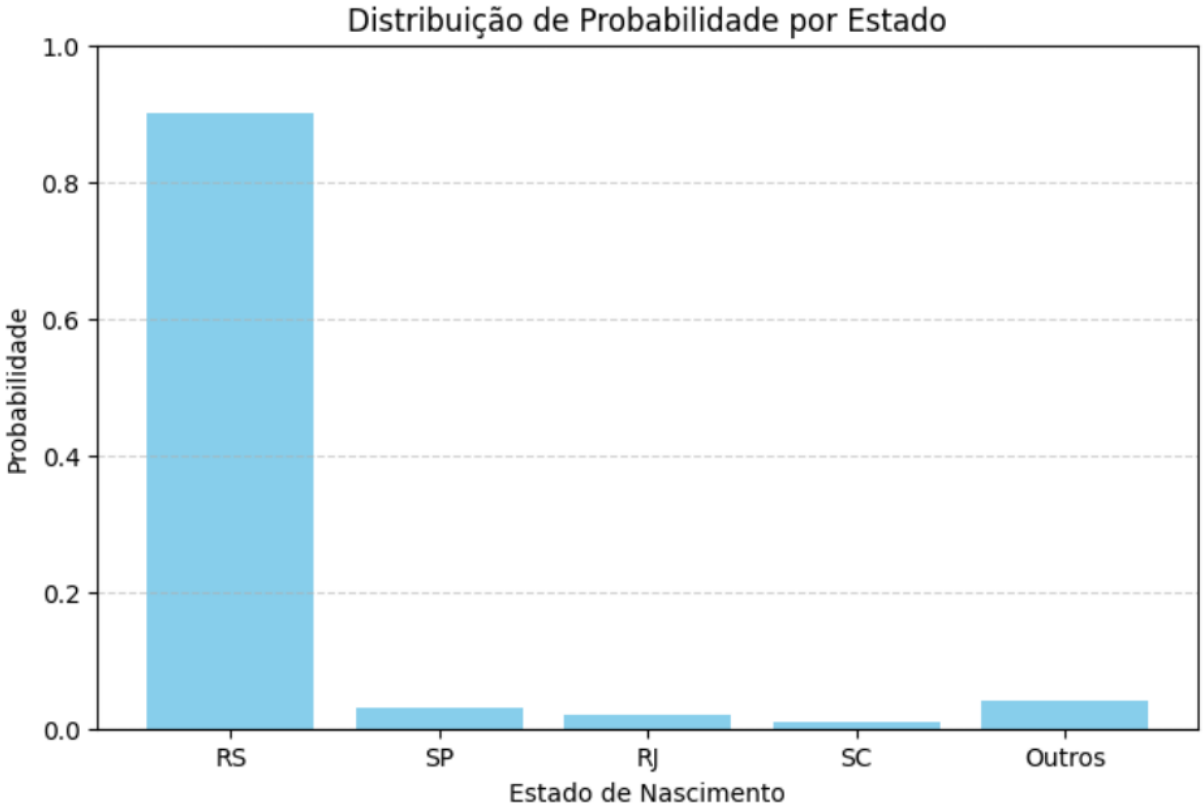

Distribuições discretas e contínuas

- **Distribuições discretas:** O número de eventos possíveis é finito.
  Exemplo: faces de um dado, estados de nascimento, número de filhos.

- **Distribuições contínuas:** Os eventos possíveis podem assumir infinitos valores dentro de um intervalo.
  Exemplo: altura das pessoas, peso, tempo de espera em uma fila.

Na distribuição contínua, não faz sentido perguntar "qual a probabilidade de alguém ter exatamente 1,6012m de altura" (essa probabilidade é praticamente zero!), mas sim em um intervalo (entre 1,60m e 1,62m, por exemplo).

> **Resumo:**
>
> - Toda distribuição de probabilidade precisa que as probabilidades estejam entre 0 e 1 e que a soma (discreta) ou área total (contínua) seja igual a 1.
> - Entender o tipo de distribuição dos seus dados é essencial para escolher o modelo matemático correto em ciência de dados e machine learning.

13. Independência de eventos e probabilidade condicional

Dois eventos são chamados de independentes quando a ocorrência de um não altera a chance do outro acontecer. O exemplo mais clássico é o lançamento de moedas: não importa se você tirou cinco "caras" seguidas, a probabilidade de dar "cara" no próximo lançamento continua sendo 50%. Cada jogada é independente das anteriores.

Matematicamente, para eventos independentes, a chance de ambos acontecerem ao mesmo tempo é o produto das probabilidades individuais:

$$P(A\ e\ B) = P(A) \times P(B)$$

Ou seja, para tirar duas "caras" seguidas, basta multiplicar 0,5 × 0,5 = 0,25.

Nem todos os eventos do cotidiano são independentes. Se um time está ganhando de 3x0 no final do jogo, a probabilidade de vitória é muito maior do que se o jogo tivesse acabado de começar. Nesses casos, há dependência entre os eventos.

Probabilidade condicional

A probabilidade condicional aparece quando o resultado de um evento interfere nas chances do outro. Por exemplo: nos Estados Unidos, cerca de 56% dos adolescentes entram na faculdade, mas esse número sobe bastante se o pai do estudante também for graduado. Assim, o histórico dos pais altera a chance do filho cursar a universidade.

A notação para probabilidade condicional é $P(A|B)$ lida como "probabilidade de A dado B". Para calcular, usamos a seguinte relação:

$$P(A|B) = \frac{P(A\ \text{e}\ B)}{P(B)}$$

Por que isso importa?

Reconhecer quando eventos são independentes (ou não) e entender a lógica da probabilidade condicional é fundamental para fazer análises corretas e tomar decisões mais embasadas, seja em ciência de dados, pesquisas, negócios ou situações do dia a dia.

14. Esperança matemática de um processo aleatório

Quando analisamos dados de um experimento ou de um processo aleatório, uma das perguntas mais comuns é: qual o valor médio que podemos esperar? Esse conceito é chamado de **esperança** ou **valor esperado**.

A esperança é, basicamente, a média ponderada dos resultados possíveis, considerando as probabilidades de cada um acontecer. Por exemplo, imagine que queremos saber quanto um estudante de psicologia gasta, em média, com livros no primeiro semestre. Se observarmos cinco alunos, que gastaram R$100, R$450, R$100, R$35 e R$0, podemos calcular a esperança desse processo.

Como calcular

Em termos práticos, se cada resultado tem a mesma chance de acontecer, a esperança é a média aritmética. Mas, em geral, cada valor pode ter sua própria probabilidade. O cálculo é feito assim:

$$E(X) = \sum [P(x_i) \times x_i]$$

Ou seja, somamos o produto da probabilidade de cada valor pelo próprio valor.

No exemplo:

- Cada um dos 5 gastos tem probabilidade de 0,2 (ou 20%).
- Esperança = 0,2 × (100 + 450 + 100 + 35 + 0) = R$137

Note que nenhum aluno gastou exatamente R$137, mas esse é o valor central, o "gasto médio esperado".

Moda: outro tipo de centralidade

Além da esperança, outro conceito importante é a **moda**, que é o valor que mais ocorre. No exemplo, a moda é R$100, já que dois alunos tiveram esse gasto.

Distribuições contínuas

Se os possíveis valores fossem infinitos (por exemplo, qualquer valor de altura possível), usaríamos uma equação matemática chamada **integral** para calcular a esperança. Mas para dados finitos, basta somar como no exemplo acima.

Resumindo

A esperança é o valor médio esperado de um processo aleatório, calculado levando em conta as probabilidades de cada resultado. É uma medida fundamental para entender tendências em dados e fazer previsões.

15. Variância e desvio padrão

Depois de entendermos a esperança (valor médio) de um processo aleatório, é importante saber o quanto os resultados podem se afastar desse valor central. Para isso, usamos o conceito de **variância**.

A variância mede a dispersão dos dados em relação à média. Ou seja, ela mostra se os resultados costumam ficar próximos ou distantes da média. Para calcular, subtraímos a média de cada valor, elevamos essa diferença ao quadrado (para evitar que diferenças negativas se anulem), somamos tudo e dividimos pelo número total de observações. Essa "média dos quadrados dos desvios" é a variância.

O motivo de elevar ao quadrado é simples: valores muito distantes da média influenciam mais a variância, pois diferenças grandes crescem ainda mais quando elevadas ao quadrado. Assim, a variância é especialmente sensível a pontos extremos.

O cálculo fica assim:

$$\text{Variância} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2$$

onde μ é a média (ou esperança) dos dados.

Para facilitar a interpretação, muitas vezes usamos o **desvio padrão**, que é simplesmente a raiz quadrada da variância. O desvio padrão traz a medida de dispersão para a mesma unidade dos dados originais, tornando mais fácil comparar e entender a variabilidade do processo.

Esses conceitos aparecem com frequência em Machine Learning, análise de dados e estatística aplicada, pois ajudam a entender tanto o "centro" dos dados quanto o "espalhamento" ao redor desse centro. Saber calcular e interpretar variância e desvio padrão é essencial para analisar qualquer conjunto de dados de forma confiável.

16. A curva de distribuição Gaussiana (Normal)

A distribuição normal, também chamada de **distribuição gaussiana**, é uma das funções matemáticas mais importantes e comuns em toda a estatística. Ela aparece em inúmeros fenômenos naturais e humanos: altura de pessoas, pesos, variações de produção industrial, notas de provas, entre outros. O formato dessa curva é conhecido como "formato de sino".

Imagine, por exemplo, que você mede a altura de centenas de homens em uma cidade. Ao organizar esses dados em um histograma, vai notar que a maioria das alturas está próxima de um valor central, com menos pessoas muito baixas ou muito altas. Esse padrão de concentração central e caudas decrescentes dos dois lados é exatamente o que define a distribuição normal.

A beleza da curva normal é que ela pode ser modelada por uma equação matemática com apenas dois parâmetros: a **média** μ, que define o centro da curva, e o **desvio padrão** σ, que determina o "alargamento" ou "estreitamento" da curva. Alterando a média, deslocamos a curva para a direita ou esquerda. Alterando o desvio padrão, deixamos a curva mais larga (valores mais dispersos) ou mais estreita (valores mais próximos da média).

Fórmula matemática

A fórmula matemática da curva normal é:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Apesar de parecer complexa, o essencial é entender que você pode ajustar a média e o desvio padrão para "encaixar" a curva nos seus dados.

Na prática, quando os dados que você analisa apresentam um histograma semelhante a um sino, você pode utilizar a distribuição normal para modelar e analisar o processo. Para isso, basta calcular a média e o desvio padrão dos seus dados (como já estudado nas aulas anteriores) e usar esses valores como parâmetros da curva.

Saber identificar e aplicar a distribuição normal é essencial em ciência de dados, já que muitos métodos estatísticos e técnicas de Machine Learning partem do pressuposto de normalidade dos dados.

Propriedades de uma distribuição gaussiana (normal)

A distribuição normal é tão especial que, independentemente dos valores da média e do desvio padrão, ela sempre apresenta as mesmas proporções de dados em torno do seu centro. Isso significa

que, uma vez que você calcula a média (μ) e o desvio padrão (σ) do seu conjunto de dados, pode usar essas informações para fazer previsões sobre a maioria dos valores.

Uma das propriedades mais importantes é que aproximadamente **68% dos dados** estarão no intervalo que vai da média menos um desvio padrão até a média mais um desvio padrão$(\mu - \sigma$ a $\mu + \sigma)$. Se ampliarmos para dois desvios padrões para cada lado $(\mu - 2\sigma$ a $\mu + 2\sigma)$, cobrimos **cerca de 95% dos dados**.
E para três desvios padrões $(\mu - 3\sigma$ a $\mu + 3\sigma)$, quase **99,7%** dos valores ficam dentro desse intervalo.

Esses percentuais são tão universais que são usados, por exemplo, em testes de QI (Quociente de Inteligência): a média do QI é 100 e o desvio padrão é 15. Isso significa que 68% das pessoas têm QI entre 85 e 115; 95% estão entre 70 e 130. Valores muito acima ou abaixo disso são raros porque estão nas extremidades da curva, onde a probabilidade é muito pequena.

Essas propriedades permitem que cientistas, analistas e profissionais de dados usem a distribuição normal para identificar comportamentos esperados e também detectar valores atípicos. Sempre que um fenômeno natural ou social tem um histograma em formato de sino, podemos modelar e prever intervalos de ocorrência com muita confiança usando a curva normal.